

Кейс 4: регрессия по функциональным данным через линейные функционалы

Во многих прикладных задачах объект наблюдения естественно задаётся не конечным вектором признаков, а функцией одной переменной. Типичные примеры: суточные кривые температуры, сигналы ЭКГ, траектории датчиков, профили нагрузки, спектры, временные ряды, наблюдаемые на фиксированном интервале. Такие объекты называют функциональными данными.

Пусть каждому объекту соответствует функция $x(t)$, заданная на интервале $[a, b]$. Требуется по функции $x(t)$ предсказать числовой ответ $y \in \mathbb{R}$. Это приводит к задаче регрессии, в которой входом является функция, а не вектор.

Естественный способ построить признаки из функции – брать значения линейных функционалов. Простейший и наиболее важный класс – интегральные функционалы вида

$$L_\varphi(x) = \int_a^b x(t)\varphi(t) dt$$

где $\varphi(t)$ – фиксированная весовая функция.

Пусть выбрана система функций

$$\varphi_1(t), \dots, \varphi_m(t)$$

Тогда по каждой функции-наблюдению $x_i(t)$ строится вектор признаков

$$z_i = (z_{i1}, \dots, z_{im}), \quad z_{ik} = L_{\varphi_k}(x_i) = \int_a^b x_i(t)\varphi_k(t) dt$$

После этого задача регрессии сводится к обычной линейной модели

$$\hat{y}_i = \beta_0 + \sum_{k=1}^m \beta_k z_{ik}$$

Задания для работы

1. Задать пространство функций и класс данных. Выбрать интервал наблюдения, например

$$[a, b] = [0, 1]$$

Предположить, что каждый объект задаётся функцией $x_i(t)$ на этом интервале.

- (a) задать равномерную сетку t_j на $[a, b]$
- (b) хранить каждую функцию как набор значений $x_i(t_j)$
- (c) реализовать численное приближение интеграла или использовать готовый метод

2. Выбрать систему линейных функционалов

Выбрать функции $\varphi_1, \dots, \varphi_m$, например:

- индикаторы подотрезков $[\tau_{k-1}, \tau_k]$
- полиномы $1, t, t^2, \dots$
- тригонометрический базис $1, \sin(2\pi t), \cos(2\pi t), \dots$
- ортонормированная система, предварительно нормированная в $L_2[a, b]$

- (a) проверить линейность каждого функционала
- (b) если система ортонормирована, проверить условия

$$\langle \varphi_k, \varphi_\ell \rangle = \delta_{k\ell}$$

(с) объяснить, какую характеристику функции измеряет каждый функционал

В колабе

(а) реализовать вычисление признаков

$$z_{ik} = \int_a^b x_i(t) \varphi_k(t) dt$$

(b) построить матрицу признаков $Z = (z_{ik})$

(с) подготовить данные для сравнения нескольких систем функционалов

3. Построить линейную модель

$$\hat{y}_i = \beta_0 + \sum_{k=1}^m \beta_k z_{ik}$$

(а) записать матричную форму модели

(b) выписать функционал МНК

$$Q(\beta) = (y - X\beta)^T (y - X\beta)$$

(с) вывести нормальные уравнения

$$X^T X \hat{\beta} = X^T y$$

(d) получить формулу решения

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

при условии обратимости $X^T X$

(е) оценить коэффициенты МНК

(f) вычислить прогнозы $\hat{y}_i$

(g) посчитать ошибки на обучающей и тестовой выборке

4. Для модели

$$\hat{y}(x) = \beta_0 + \sum_{k=1}^m \beta_k \langle x, \varphi_k \rangle$$

можно ввести функцию

$$w(t) = \sum_{k=1}^m \beta_k \varphi_k(t)$$

тогда модель переписывается как

$$\hat{y}(x) = \beta_0 + \langle x, w \rangle$$

показать равенство

$$\sum_{k=1}^m \beta_k \langle x, \varphi_k \rangle = \left\langle x, \sum_{k=1}^m \beta_k \varphi_k \right\rangle$$

(а) восстановить функцию весов $w(t)$

(b) построить её график

(с) сравнить $w(t)$ для разных наборов функционалов

5. Сравнить разные наборы функционалов

Рассмотреть как минимум два разных способа построения признаков, например:

- средние значения на подинтервалах;
 - проекции на тригонометрический базис.
- обучить модель для каждого набора функционалов
 - сравнить качество прогноза по метрикам MSE, RMSE, R^2
 - сравнить устойчивость коэффициентов
6. Исследовать влияние числа функционалов
- изменяйте m (число функционалов) в некотором диапазоне
 - для каждого m измерять ошибку на обучении и тесте
 - построить графики качества от m
7. Добавить регуляризацию
- $$Q_\lambda(\beta) = (y - X\beta)^T(y - X\beta) + \lambda\|\beta\|_2^2$$
- вывести формулу решения

$$\hat{\beta}_\lambda = (X^T X + \lambda I)^{-1} X^T y$$
 - пояснить, как регуляризация влияет на устойчивость оценок
 - реализовать ridge-регрессию
 - сравнить её с обычным МНК
 - исследовать зависимость качества от параметра λ
8. Исследовать устойчивость к шуму и к изменению сетки

Данные для работы

1. Синтетические данные

Пусть каждая функция имеет вид

$$x_i(t) = a_i \sin(2\pi t) + b_i \cos(2\pi t) + c_i t + \varepsilon_i(t), \quad t \in [0, 1]$$

где коэффициенты a_i, b_i, c_i случайны, а $\varepsilon_i(t)$ – небольшой шум.

Тогда целевой ответ можно задать, например, формулой

$$y_i = 2 \int_0^1 x_i(t) \sin(2\pi t) dt - \int_0^1 x_i(t) t dt + \eta_i$$

где η_i – шум в ответе.

2. Кусочно-гладкие функции Можно генерировать функции с локальными особенностями:

$$x_i(t) = \alpha_i \mathbb{1}(t \in [0, 0.3]) + \beta_i \mathbb{1}(t \in [0.3, 0.7]) + \gamma_i \mathbb{1}(t \in [0.7, 1]) + \varepsilon_i(t)$$

3. Реальные данные

- почасовые профили потребления электроэнергии
- суточные температурные кривые
- сигналы ЭКГ или ЭЭГ

Здесь запись можно интерпретировать как функцию, заданную на сетке, а ответом может быть скалярная характеристика: максимальная нагрузка, средняя температура следующего дня, клинический показатель.