

Кейс 6: метрические методы регрессии

Пусть дана обучающая выборка

$$X^\ell = \{(x_i, y_i)\}_{i=1}^\ell, \quad x_i \in \mathbb{R}^n, \quad y_i \in \mathbb{R}$$

Предполагается, что выполняется гипотеза непрерывности: близким объектам соответствуют близкие ответы.

Рассматривается задача непараметрической регрессии на основе ядерного сглаживания. Для объекта x требуется оценить значение регрессии по формуле Надарая–Ватсона:

$$a(x; X^\ell, h) = \frac{\sum_{i=1}^{\ell} y_i K\left(\frac{\rho(x, x_i)}{h}\right)}{\sum_{i=1}^{\ell} K\left(\frac{\rho(x, x_i)}{h}\right)}$$

где $K(r)$ – ядро, $h > 0$ – ширина окна, $\rho(x, x_i)$ – расстояние между объектами.

Также требуется исследовать вариант переменной ширины окна:

$$h(x) = \rho(x, x_{(k+1)})$$

и оценку

$$a(x; X^\ell, k) = \frac{\sum_{i=1}^{\ell} y_i K\left(\frac{\rho(x, x_i)}{\rho(x, x_{(k+1)})}\right)}{\sum_{i=1}^{\ell} K\left(\frac{\rho(x, x_i)}{\rho(x, x_{(k+1)})}\right)}$$

Оценка Надарая–Ватсона может быть получена как решение задачи локально взвешенного метода наименьших квадратов при локальной модели

$$f(x_i) \approx \theta$$

то есть

$$Q(\theta; x) = \sum_{i=1}^{\ell} K\left(\frac{\rho(x, x_i)}{h}\right) (\theta - y_i)^2 \rightarrow \min_{\theta}$$

Для борьбы с выбросами предлагается исследовать робастную схему LOWESS. На итерации вычисляются LOO-оценки

$$a_i = \frac{\sum_{j=1, j \neq i}^{\ell} y_j \gamma_j K\left(\frac{\rho(x_i, x_j)}{h(x_i)}\right)}{\sum_{j=1, j \neq i}^{\ell} \gamma_j K\left(\frac{\rho(x_i, x_j)}{h(x_i)}\right)}$$

после чего объектные веса обновляются по правилу

$$\gamma_i = \tilde{K}\left(\frac{|a_i - y_i|}{6 \operatorname{med}\{\varepsilon_i\}}\right), \quad \varepsilon_i = |a_i - y_i|$$

Требуется исследовать, как выбор ядра, ширины окна и робастного «перевзвешивания» влияет на качество регрессии и устойчивость к выбросам.

Задания для работы

1. Реализовать с нуля:

- ядерную регрессию Надарая–Ватсона с фиксированным окном
- ядерную регрессию Надарая–Ватсона с переменным окном

- робастную регрессию LOWESS
2. Реализовать подбор параметров h , k и ядра K по LOO или кросс-валидации.
 3. Сравнить не менее трёх ядер, например:
 - гауссовское
 - квадратичное
 - треугольное
 - Епанечникова
 4. Для одномерной синтетической задачи построить графики:
 - истинной функции
 - наблюдений
 - прогноза при разных значениях h
 - зависимости ошибки от h
 - зависимости ошибки от числа соседей k для переменного окна
 5. Для реальных датасетов оценить качество по метрикам:
 - MAE
 - RMSE
 - R^2
 6. Добавить в данные искусственные выбросы и сравнить обычную ядерную регрессию и LOWESS.
 7. Построить графики:
 - веса γ_i после стабилизации LOWESS
 - сравнение кривых прогноза до и после робастного перевзвешивания
 - распределение ошибок на объектах
 8. Исследовать:
 - что влияет на качество сильнее – выбор ядра или выбор ширины окна
 - когда переменное окно выигрывает у фиксированного
 - при каком уровне загрязнения данных LOWESS начинает выигрывать у обычного сглаживания

Данные для работы

Для выполнения задания рекомендуется использовать не менее двух реальных датасетов и один синтетический.

- Diabetes – компактный датасет для регрессии
- California Housing – задача регрессии с признаками разного масштаба
- Синтетическая одномерная задача вида $y = \sin x + \varepsilon$
- Синтетическая одномерная задача с выбросами для исследования LOWESS