

Регрессия по функциональным данным: линейные функционалы Рисса и метрические оценки Надарая--Ватсона

Тищенко Павел Валерьевич

Национальный исследовательский университет ИТМО,
факультет технологий искусственного интеллекта, группа J3210,
Санкт-Петербург, Россия

ilyavoronin200603@gmail.com github.com/paulhowever/funkan_tischenko_j3210

18 мая 2026 г., Санкт-Петербург

Аннотация. В работе исследуется задача восстановления вещественной зависимой переменной по объекту, заданному функцией $x \in L_2[0, 1]$ или вектором табличных признаков $x \in \mathbb{R}^d$. Подход разделён на два этапа. На первом этапе функция сжимается в конечномерный вектор линейных функционалов вида $z_k = \langle x, \varphi_k \rangle$, где $\varphi_k \in L_2[0, 1]$ играют роль шаблонов; по теореме Рисса любой непрерывный линейный функционал в гильбертовом пространстве представим в такой форме, что превращает шаг в чисто геометрическое проектирование. На втором этапе по вектору z строится регрессия --- либо параметрическая (МНК и ridge), либо непараметрическая (Надарая--Ватсон с фиксированным и переменным окном, робастная схема LOWESS). На синтетических функциональных данных, где истинная зависимость линейна по интегральным функционалам, лучший линейный базис (тригонометрический, $m = 9$) достигает $\text{test } R^2 = 0,993$ при ridge-параметре $\lambda \rightarrow 0$. Эксперименты с ядерной регрессией показывают, что вариация ширины окна h меняет LOO RMSE в 5--6 раз сильнее, чем выбор ядра, в полном соответствии с асимптотической теорией Парзена--Розенблатта. На загрязнённых выбросах данных схема LOWESS оказывается строго лучше Надарая--Ватсона начиная с доли загрязнения $\sim 3\%$: RMSE падает с 0,221 до 0,176. На стандартных табличных датасетах *Diabetes* ($R^2 = 0,46$) и *California Housing* ($R^2 = 0,65$) переменное окно даёт небольшой устойчивый выигрыш над фиксированным. Полученные результаты подтверждают: линейные модели по функциональным признакам и метрические методы являются взаимодополняющими инструментами и совместно покрывают как глобальную интерпретируемость, так и гибкую локальную аппроксимацию.

Ключевые слова: функциональный анализ; теорема Рисса о представлении; линейная регрессия; ridge-регуляризация; ядерная регрессия; оценка Надарая--Ватсона; LOWESS; М-оценки; кросс-валидация leave-one-out.

Классификация MSC 2020: 46E20, 41A45, 62G08, 62J07.

1. Введение

1.1. Постановка проблемы

Во многих прикладных задачах --- от обработки физических сигналов до анализа медицинских временных рядов --- объект наблюдения естественно описывается не числовым вектором, а функцией $x: [0, 1] \rightarrow \mathbb{R}$. По этой функции требуется предсказать скаляр $y \in \mathbb{R}$. Прямая регрессия на пространстве $L_2[0, 1]$ бесконечномерна, поэтому первым шагом всегда выступает <<сжатие>> функции в конечный набор признаков $z \in \mathbb{R}^m$, не разрушающее главную структуру сигнала. Естественной операцией здесь является применение к x непрерывных линейных функционалов; теорема Рисса показывает, что любой такой функционал имеет интегральную форму, и тем самым шаг признаков становится прозрачной геометрической операцией в гильбертовом пространстве [1, 2].

После сжатия задача регрессии становится конечномерной, и к ней применимы как параметрические (линейная регрессия и её регуляризованные модификации [3, 4]), так и непараметрические методы. Среди последних базовыми являются ядерные оценки Надарая--Ватсона [6, 7] и их робастная локально-полиномиальная модификация LOWESS, предложенная У. Кливлендом [12, 13]. Эти два

класса методов покрывают противоположные стороны bias--variance: линейная модель обладает низкой дисперсией и высокой интерпретируемостью, ядерная --- высокой гибкостью при росте смещения с увеличением окна.

1.2. Цели и вклад работы

Цель исследования --- объединить оба подхода в единую численно и теоретически последовательную схему, провести сквозную серию экспериментов и проинтерпретировать результаты в терминах классической теории функциональной аппроксимации. Конкретный вклад работы:

1. программно реализован и проверен на линейность набор интегральных функционалов трёх типов: индикаторного, полиномиального и тригонометрического;
2. построена и сравнена линейная регрессия (МНК, ridge) над получившимися признаками с восстановлением весовой функции $w(t) \in L_2[0, 1]$;
3. с нуля реализованы Надарая--Ватсон (фиксированное и переменное окно) и итеративный LOWESS с биквадратными весами; подобраны гиперпараметры через векторизованную LOO-кросс-валидацию;
4. проведено эмпирическое сопоставление чувствительности модели к ширине окна и выбору ядра с асимптотической формулой Парзена; показано количественное соответствие;
5. экспериментально определён порог доли выбросов, начиная с которого LOWESS становится строго лучше Надарая--Ватсона;
6. методы применены к двум классическим табличным датасетам (*Diabetes*, *California Housing*) и проинтерпретированы в контексте curse of dimensionality.

1.3. Структура работы

Раздел 2 фиксирует обозначения и приводит необходимые сведения функционального анализа. Раздел 3 посвящён параметрической схеме: интегральным функционалам, нормальным уравнениям и ridge-регуляризации. Раздел 4 разрабатывает непараметрическую часть --- от оценки Надарая--Ватсона до робастной LOWESS. В разделе 5 приведены численные эксперименты на трёх датасетах. Раздел 6 интерпретирует результаты в контексте известной теории; раздел 7 подводит итоги. Исходный код, тесты и пайплайн пересборки графиков опубликованы в открытом репозитории.

2. Математические предпосылки

2.1. Гильбертово пространство $L_2[0, 1]$

Рассмотрим пространство $L_2[0, 1]$ классов эквивалентности измеримых функций $x: [0, 1] \rightarrow \mathbb{R}$ со скалярным произведением

$$\langle x, y \rangle = \int_0^1 x(t)y(t) dt, \quad \|x\|^2 = \langle x, x \rangle.$$

Пространство $L_2[0, 1]$ полно по индуцированной норме, то есть является гильбертовым. Сильная топология индуцируется нормой, слабая --- семейством функционалов $x \mapsto \langle x, \varphi \rangle$ при $\varphi \in L_2[0, 1]$.

Теорема 1 (Рисс--Фишер, см. [1, гл. III]). Пусть H --- гильбертово пространство и $L: H \rightarrow \mathbb{R}$ --- непрерывный (эквивалентно --- ограниченный) линейный функционал. Тогда существует единственный элемент $\varphi_L \in H$ такой, что $L(x) = \langle x, \varphi_L \rangle$ для всех $x \in H$, причём $\|L\| = \|\varphi_L\|$.

Теорема 1 означает, что в $L_2[0, 1]$ все разумные скалярные числовые характеристики функции автоматически имеют интегральную запись со специальной функцией-шаблоном φ . Это превращает шаг извлечения признаков в чисто геометрическую операцию и снимает любую двусмысленность в выборе функционалов: задача сводится к выбору хорошего набора шаблонов $\{\varphi_k\}_{k=1}^m \subset L_2[0, 1]$.

2.2. Конечномерное представление

Зафиксировав систему функционалов $\{\varphi_k\}_{k=1}^m$, каждой функции $x_i \in L_2[0, 1]$ ставится в соответствие вектор признаков

$$z_i = (z_{i1}, \dots, z_{im}) \in \mathbb{R}^m, \quad z_{ik} = \langle x_i, \varphi_k \rangle.$$

Дальнейшие модели работают уже над z_i . Если в качестве $\{\varphi_k\}$ выбрана ортонормированная система, то z_i суть коэффициенты Фурье функции x_i в этой системе; в общем случае $\{\varphi_k\}$ может быть неортогональной, и тогда матрица Грама $G_{kl} = \langle \varphi_k, \varphi_l \rangle$ участвует в нормальных уравнениях.

2.3. Обозначения

Далее по тексту используются обозначения, приведённые в таблице 1. Жирный шрифт зарезервирован за матрицами и векторами в $\mathbb{R}^n$ при $n > 1$; обычный --- за скалярами и функциями.

Таблица 1. Сводка основных обозначений.

Символ	Смысл
$x(t), y$	функция-объект $x \in L_2[0, 1]$ и скалярный отклик $y \in \mathbb{R}$
φ_k	k -й функционал-шаблон, $\varphi_k \in L_2[0, 1]$
$z_{ik} = \langle x_i, \varphi_k \rangle$	признак, генерируемый функционалом
m	число функционалов
$Z \in \mathbb{R}^{n \times m}$	матрица признаков, $X = [1 \mid Z]$ --- с константой
$\beta \in \mathbb{R}^{m+1}$	вектор коэффициентов линейной модели
$\lambda \geq 0$	параметр ridge-регуляризации
$w(t) = \sum_k \beta_k \varphi_k(t)$	восстановленная весовая функция
n (или ℓ)	число обучающих объектов
$K: \mathbb{R} \rightarrow \mathbb{R}_+$	ядро ($\int K = 1$, симметричное)
$h > 0$	ширина окна (фиксированная)
k	число соседей (для переменного окна)
$\rho(x, x_i)$	евклидово расстояние в $\mathbb{R}^m$
$\gamma_i \in [0, 1]$	вес наблюдения в LOWESS
T	число LOWESS-итераций

3. Линейная регрессия по функциональным признакам

3.1. Функционалы интегрального вида

В работе используются три системы шаблонов, охватывающие принципиально разные геометрические предположения о структуре сигнала:

- *индикаторы подотрезков*: $\varphi_k(t) = \mathbf{1}_{[\tau_{k-1}, \tau_k]}(t)$, дающие средние значения функции на разбиении $\{\tau_k\}$ --- разумны при кусочно-стационарном сигнале;
- *полиномиальный базис*: $\varphi_k(t) = t^{k-1}$, $k = 1, \dots, m$ --- захватывает медленные моменты функции, переусложняется для колебательных сигналов из-за плохой обусловленности;
- *тригонометрический базис*: $\{1, \sin(2\pi t), \cos(2\pi t), \sin(4\pi t), \cos(4\pi t), \dots\}$ --- короткий отрезок ряда Фурье; подходит для периодической компоненты.

Программно проверена линейность функционалов: для случайно сгенерированных $\alpha, \beta \in \mathbb{R}$ и пар $x, y \in L_2[0, 1]$ невязка $|L_\varphi(\alpha x + \beta y) - \alpha L_\varphi(x) - \beta L_\varphi(y)|$ по всем функционалам не превышает 10^{-9} , что обусловлено погрешностью квадратурной формулы (см. подраздел 3.2).

3.2. Квадратурное вычисление

Функции хранятся на равномерной сетке $\{t_j\}_{j=0}^{N-1}$ из $N = 320$ узлов с шагом $\Delta t = 1/(N - 1)$. Скалярные произведения вычисляются по составной формуле трапеций:

$$\langle x, \varphi_k \rangle \approx \sum_{j=0}^{N-2} \frac{x(t_j)\varphi_k(t_j) + x(t_{j+1})\varphi_k(t_{j+1})}{2} \Delta t.$$

Предложение 1 (остаточный член). Если $g = x\varphi_k \in C^2[0, 1]$, то остаточный член составной трапеции имеет вид $-\frac{1}{12}\Delta t^2(g'(1) - g'(0)) + O(\Delta t^4)$.

Для $N = 320$ это даёт абсолютную погрешность порядка 10^{-5} , что заведомо меньше дисперсии шума отклика ($\sim 10^{-2}$) и поэтому не вносит систематического смещения. Альтернатива --- формула Симпсона ($O(\Delta t^4)$) или гауссовы квадратуры; в данной задаче они избыточны.

3.3. МНК и нормальные уравнения

После сборки $Z \in \mathbb{R}^{n \times m}$ и расширения столбцом единиц $X = [\mathbf{1} \mid Z] \in \mathbb{R}^{n \times (m+1)}$ линейная модель имеет вид $\hat{y} = X\beta$. Метод наименьших квадратов минимизирует

$$Q(\beta) = \|y - X\beta\|^2 = (y - X\beta)^\top (y - X\beta).$$

Лемма 1. Стационарная точка Q удовлетворяет нормальным уравнениям $X^\top X \hat{\beta} = X^\top y$. При полном столбцовом ранге X матрица $X^\top X$ положительно определена, поэтому $\hat{\beta} = (X^\top X)^{-1} X^\top y$ доставляет глобальный минимум.

Доказательство. $\nabla Q(\beta) = -2X^\top (y - X\beta) = 0$ даёт указанные уравнения. Гессиан $\nabla^2 Q = 2X^\top X \succeq 0$ всегда положительно полуопределён, при полном ранге --- строго положительно определён; следовательно, Q выпукла, а стационарная точка --- глобальный минимум. $\square$

3.4. Ridge-регуляризация

При большом m или сильной зависимости функционалов $X^\top X$ становится плохо обусловленной, и $\hat{\beta}$ сильно колеблется от выборки к выборке. Ridge [3] добавляет к функционалу штраф $\lambda \|\beta\|^2$ ($\lambda \geq 0$):

$$Q_\lambda(\beta) = \|y - X\beta\|^2 + \lambda \|\beta\|^2, \quad \hat{\beta}_\lambda = (X^\top X + \lambda I)^{-1} X^\top y.$$

Матрица $X^\top X + \lambda I$ всегда положительно определена при $\lambda > 0$, поэтому решение существует и единственно даже при сингулярном $X^\top X$. Спектрально это означает сдвиг всех собственных чисел $X^\top X$ на λ --- подавление направлений с малой собственной информативностью.

Замечание 1. В терминах bias--variance: МНК-оценка несмещённая, но при плохой обусловленности её дисперсия растёт пропорционально $1/\sigma_{\min}^2(X)$. Ridge вносит смещение $O(\lambda)$, но уменьшает дисперсию на большую величину; при оптимальном λ суммарная MSE предсказания меньше, чем у обычного МНК. Это частный случай теоремы Джеймса--Стейна о доминированности несмещённой оценки в размерности ≥ 3 [5].

3.5. Восстановление весовой функции

Обученная линейная модель имеет вид $\hat{y}(x) = \beta_0 + \sum_{k=1}^m \beta_k \langle x, \varphi_k \rangle$. Введём

$$w(t) = \sum_{k=1}^m \beta_k \varphi_k(t).$$

По линейности скалярного произведения

$$\langle x, w \rangle = \left\langle x, \sum_k \beta_k \varphi_k \right\rangle = \sum_k \beta_k \langle x, \varphi_k \rangle,$$

поэтому $\hat{y}(x) = \beta_0 + \langle x, w \rangle$. Иными словами, бесконечномерная задача регрессии по функции x сводится к одному скалярному произведению с фиксированной функцией $w(t) \in L_2[0, 1]$ --- это даёт прямую интерпретацию: участки t , где $|w(t)|$ велико, сильнее всего влияют на предсказание.

4. Метрические методы регрессии

4.1. Гипотеза непрерывности и метрика

Метрические методы основаны на *гипотезе непрерывности*: условное математическое ожидание $f(x) = \mathbb{E}[y | x]$ предполагается непрерывным по x , то есть близким объектам должны соответствовать близкие ответы. В признаковом пространстве $\mathbb{R}^m$ в качестве метрики берётся евклидово расстояние

$$\rho(x, x_i) = \sqrt{\sum_{k=1}^m (x_k - x_{ik})^2}.$$

Для табличных признаков обязательна предварительная стандартизация (z-score относительно обучающей выборки): иначе компонента с большим масштабом доминирует в ρ , и модель фактически игнорирует остальные.

4.2. Оценка Надарая--Ватсона

Локально взвешенное среднее ответов обучающих объектов

$$a(x; X^\ell, h) = \frac{\sum_{i=1}^{\ell} y_i K(\rho(x, x_i)/h)}{\sum_{i=1}^{\ell} K(\rho(x, x_i)/h)} \quad (1)$$

впервые предложено независимо Надарая [6] и Уотсоном [7] как plug-in оценка условного математического ожидания через ядерную оценку плотности Парзена--Розенблатта [8].

Предложение 2 (локально-взвешенный МНК). *Оценка (1) есть решение задачи $\min_{\theta \in \mathbb{R}} \sum_{i=1}^{\ell} w_i (\theta - y_i)^2$ с весами $w_i = K(\rho(x, x_i)/h)$.*

Доказательство. $\frac{dQ}{d\theta} = 2 \sum_i w_i (\theta - y_i) = 0$, откуда $\hat{\theta} = \sum w_i y_i / \sum w_i$. Вторая производная $2 \sum w_i > 0$, поэтому это глобальный минимум. $\square$

4.3. Фиксированное и переменное окно

4.3.1. Фиксированное

При $h = \text{const}$ малое h даёт высокую чувствительность к шуму (большая дисперсия), большое h --- сильное сглаживание (большое смещение). Асимптотически (при $\ell \rightarrow \infty$, $h = h(\ell) \rightarrow 0$, $\ell h \rightarrow \infty$) MSE прогноза в точке x для гладкой регрессионной функции f раскладывается как

$$\text{MSE}(x) \approx \underbrace{\left[\frac{h^2}{2} \mu_2(K) f''(x) \right]^2}_{\text{смещение}^2, \uparrow h} + \underbrace{\frac{\sigma^2 R(K)}{\ell h p(x)}}_{\text{дисперсия}, \downarrow h}, \quad (2)$$

где $\mu_2(K) = \int r^2 K(r) dr$, $R(K) = \int K^2(r) dr$, $p(x)$ --- плотность распределения объектов [11]. Минимизация по h даёт $h^* \sim \ell^{-1/5}$, и при этом RMSE убывает как $\ell^{-2/5}$. Из (2) видно, что выбор ядра меняет лишь постоянные $\mu_2(K)$, $R(K)$, тогда как выбор h влияет на сам порядок сходимости. Это теоретическое обоснование экспериментального вывода (подраздел 5.4) о доминировании h .

В размерности d оценка (2) обобщается, давая $h^* \sim n^{-1/(4+d)}$ и $\text{RMSE} \sim n^{-2/(4+d)}$ --- классическая формула <<проклятия размерности>> [10].

4.3.2. Переменное

В переменном варианте ширина окна адаптируется к локальной плотности данных:

$$h(x) = \rho(x, x_{(k+1)}),$$

где $x_{(k+1)}$ --- $(k+1)$ -й по близости к x объект обучения. В плотных областях окно сужается, в разреженных --- расширяется. Это особенно полезно, если плотность $p(x)$ существенно неоднородна.

4.4. Ядра

Сравниваются четыре ядра, нормированных к $\int K = 1$:

$$K_g(r) = \frac{1}{\sqrt{2\pi}} e^{-r^2/2}, \quad K_\Delta(r) = (1 - |r|) \mathbf{1}_{|r| \leq 1},$$

$$K_E(r) = \frac{3}{4} (1 - r^2) \mathbf{1}_{|r| \leq 1}, \quad K_q(r) = \frac{15}{16} (1 - r^2)^2 \mathbf{1}_{|r| \leq 1}.$$

Гауссовское имеет неограниченный носитель, остальные три --- компактный $|r| \leq 1$. Ядро Епанечникова в смысле минимума асимптотической MSE оптимально [9], но эффективность остальных близка к 1 (различие $< 5\%$), что подтверждается на практике.

4.5. Робастная схема LOWESS

Обычная Надарая--Ватсон считает все объекты равноправными, и единственный выброс может ощутимо сместить прогноз в своей окрестности. LOWESS [12] --- итеративный М-оцениватель: на каждой итерации $t = 1, 2, \dots, T$ вычисляются leave-one-out прогнозы, формируются невязки и веса понижаются для объектов с большими невязками:

$$a_i = \frac{\sum_{j \neq i} y_j \gamma_j K(\rho(x_i, x_j)/h(x_i))}{\sum_{j \neq i} \gamma_j K(\rho(x_i, x_j)/h(x_i))}, \quad (3)$$

$$\varepsilon_i = |a_i - y_i|, \quad \gamma_i \leftarrow \tilde{K}\left(\frac{\varepsilon_i}{6 \operatorname{med}\{\varepsilon\}}\right), \quad (4)$$

$$\tilde{K}(u) = (1 - u^2)^2 \mathbf{1}_{|u| < 1}. \quad (5)$$

Стартовые $\gamma_i = 1$; итерации продолжаются до тех пор, пока $\max_i |a_i^{(t)} - a_i^{(t-1)}|$ не упадёт ниже порога (10^{-5} в реализации) или $t > T_{\max}$.

4.5.1. Почему именно эта формула

Множитель $6 \operatorname{med}\{\varepsilon\}$ есть робастная оценка масштаба шума. Для нормально распределённых остатков $\operatorname{med}\{|\varepsilon|\} \approx 0,6745\sigma$, поэтому $6 \operatorname{med}\{\varepsilon\} \approx 4\sigma$. Объекты с $\varepsilon_i > 4\sigma$ получают $\gamma_i = 0$ и полностью игнорируются, что делает оценку нечувствительной к примерно 25% выбросов произвольной амплитуды при асимптотической эффективности $\sim 95\%$ для нормального шума [14].

Предложение 3 (М-оценка Тьюки). *Биквадратные веса $\gamma_i = (1 - (\varepsilon_i/c)^2)^2 \mathbf{1}_{|\varepsilon_i| < c}$ суть IRLS-веса для функции потерь Тьюки $\rho_T(\varepsilon) = \frac{c^2}{6} (1 - (1 - (\varepsilon/c)^2)^3)$ при $|\varepsilon| < c$ и $c^2/6$ иначе. LOWESS отличается тем, что применяет процедуру локально (в каждой точке оценки), а параметр $c = 6 \operatorname{med}\{\varepsilon\}$ выбирается данным.*

4.5.2. Сходимость и реализация

Строгих гарантий сходимости итерационной схемы LOWESS в общем случае нет: веса γ_i зависят от текущих невязок, и градиентного спуска относительно фиксированной целевой функции тут не получается. На практике, однако, наблюдается устойчивое затухание: за 5--10 итераций изменение прогнозов падает ниже 10^{-5} . Вычислительная сложность --- $O(\ell^2)$ на итерацию, $O(\ell^2 T)$ суммарно при $T \sim 10$.

При $\operatorname{med}\{\varepsilon\} \rightarrow 0$ (например, на тривиальной выборке, где модель попадает в y точно) деление в $\tilde{K}$ становится бессмысленным; в реализации в этом случае итерации останавливаются, и возвращается уже посчитанный прогноз a , а не неинициализированный буфер. На это есть отдельный регрессионный тест.

4.6. Подбор гиперпараметров через LOO

h , k и тип ядра подбираются по leave-one-out RMSE на обучающей части:

$$\text{LOO RMSE} = \sqrt{\frac{1}{\ell} \sum_{i=1}^{\ell} (y_i - \hat{y}_i^{(-i)})^2}.$$

Для оценки (1) полная переобучка не требуется: достаточно один раз собрать матрицу ядерных весов $W_{ij} = K(\rho(x_i, x_j)/h)$ и обнулить диагональ. Это даёт $O(\ell^2)$ вместо наивного $O(\ell^3)$ --- оптимизация, ключевая для практических расчётов на $\ell \sim 10^3$ объектов.

Замечание 2. Подбор гиперпараметров всегда производится по обучающей части. Использование тестовой выборки для подбора привело бы к оптимистично смещённой оценке качества и сделало бы тест статистически зависимым от модели.

5. Численные эксперименты

5.1. Датасеты

Синтетические функциональные данные. Генерируются по схеме

$$x_i(t) = a_i \sin(2\pi t) + b_i \cos(2\pi t) + c_i t + \varepsilon_i(t), \quad y_i = 2 \int_0^1 x_i(t) \sin(2\pi t) dt - \int_0^1 x_i(t) t dt + \eta_i,$$

где $a_i, b_i, c_i \sim \mathcal{N}(0, 1)$, $\varepsilon_i(t)$ --- дискретный гауссовский белый шум, $\eta_i \sim \mathcal{N}(0, \sigma_y^2)$. Истинная зависимость линейна по интегральным функционалам: $w(t) = 2 \sin(2\pi t) - t$. Это позволяет напрямую проверить качество восстановления w в линейной модели и одновременно даёт sanity-check для следующих метрических методов.

Реальные табличные датасеты. *Diabetes* (sklearn, $n = 442$, $d = 10$) --- индекс прогрессирования диабета через год после базовых клинических измерений; стандартный бенчмарк-датасет. *California Housing* (sub-sample $n = 3000$ из 20 640, $d = 8$) --- медианная цена дома в 10^5 долларов в районах переписи 1990 г.

Подготовка. Все признаки z-стандартизируются на обучающей части (критично для метрических методов). Разделение train/test --- 75/25 случайной перестановкой, фиксированный `seed = 42`.




Рис. 1. Примеры сгенерированных функциональных данных $x_i(t)$ (отрезок $[0, 1]$, $N = 320$ узлов). Видна сильная периодическая компонента из синусоиды/косинусоиды, линейный тренд $c_i t$ и аддитивный шум $\varepsilon_i(t)$. Истинная зависимость отклика задана $w(t) = 2 \sin(2\pi t) - t$.

5.2. Метрики качества

Используется стандартный набор регрессионных метрик:

$$\text{MAE} = \frac{1}{n} \sum_i |y_i - \hat{y}_i|, \quad \text{MSE} = \frac{1}{n} \sum_i (y_i - \hat{y}_i)^2, \quad \text{RMSE} = \sqrt{\text{MSE}}, \quad R^2 = 1 - \frac{\text{SS}_{\text{res}}}{\text{SS}_{\text{tot}}}.$$

MAE устойчива к выбросам, RMSE сильнее штрафует большие ошибки (соответствует гауссовскому шуму), R^2 показывает долю объяснённой дисперсии и удобен для сравнения моделей в разных шкалах.

5.3. Результаты: линейная регрессия по функциональным признакам




Рис. 2. (Слева) Восстановленные весовые функции $w(t)$ для трёх систем функционалов: индикаторного (кусочно-постоянная), полиномиального (гладкая) и тригонометрического (точно следует $2 \sin(2\pi t) - t$). (Справа) Лучший test RMSE для каждого базиса; тригонометрический даёт минимум при $m = 3$.




Рис. 3. (Слева) Зависимость test RMSE от числа функционалов m для трёх базисов: видны точки минимума и эффект переусложнения после оптимального m . (Справа) Зависимость test RMSE от параметра ridge λ при оптимальной размерности: при малом m модель уже хорошо обусловлена, регуляризация почти не даёт выигрыша.

Таблица 2. Лучшие линейные модели на синтетических данных ($train/test = 75/25$, $\sigma_y \approx 0,71$).

Конфигурация	test RMSE	test MAE	test R^2
Тригонометрический, $m = 9$, $\lambda \rightarrow 0$	0,094	0,075	0,993
Индикаторный, $m \approx 11$	$\sim 0,40$	$\sim 0,30$	$\sim 0,90$
Полиномиальный, $m \approx 5$	$\sim 0,55$	$\sim 0,40$	$\sim 0,80$

Тригонометрический базис побеждает ожидаемо: целевая переменная задана через $\sin(2\pi t)$ и t , и функционалы напрямую согласованы с этой структурой. Полиномиальный базис страдает оттого, что для воспроизведения $\sin(2\pi t)$ необходимо много полиномов; индикаторный --- от кусочно-постоянной природы аппроксимации $\sin(2\pi t)$, шумящей на стыках отрезков. Оптимальное λ близко к нулю: при малом m модель уже хорошо обусловлена.




Рис. 4. Лучшая линейная модель (тригонометрический базис, $m = 9$). (Слева) Истинные и предсказанные значения y на тестовой выборке: точки лежат вдоль диагонали $y = \hat{y}$. (Справа) Распределение остатков $y - \hat{y}$: симметрично около нуля, без тяжёлых хвостов --- модель не имеет систематических смещений и шум, не объяснённый ею, действительно близок к $\mathcal{N}(0, \sigma^2)$.

5.4. Результаты: ядерная регрессия на 1D-синтетике

Для визуальной диагностики ядерной оценки построена 1D-задача $y = \sin x + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, 0.12^2)$, $n = 220$.




Рис. 5. 1D-синтетика. (Слева) Оценка Надарая--Ватсона при разных h : при $h = 0,1$ --- переобучение (зазубрины), при $h = 0,8$ --- пересглаживание (сдвиг к среднему). (Справа) Классическая U-образная зависимость LOO RMSE от h : оптимум около $h \approx 0,3$ соответствует предсказанию (2).




Рис. 6. LOO RMSE четырёх ядер: (слева) как функция ширины фиксированного окна h , (справа) как функция числа соседей k для переменного окна. Кривые разных ядер почти сливаются --- ядро влияет существенно слабее, чем сам выбор гиперпараметра. Размах LOO RMSE по h составляет $\Delta \approx 0,018$, тогда как при фиксированном $h = 0,3$ смена ядра даёт $\Delta \approx 0,003$.

Таблица 3. Лучшие ядерные модели по каждому из четырёх ядер, фиксированное окно, 1D-синтетика. Различие в test RMSE между лучшим и худшим ядром --- 0,010 при разбросе по h в ~ 6 раз больше.

Ядро	h^*	LOO RMSE	test RMSE	test MAE	test R^2
gaussian	0,25	0,818	0,539	0,263	0,691
epanechnikov	0,50	0,816	0,545	0,266	0,685
triangular	0,50	0,820	0,545	0,269	0,684
quartic	0,80	0,817	0,535	0,259	0,696




Рис. 7. (Слева) Сводное сравнение лучшего test RMSE по каждому ядру --- все четыре практически идентичны, что согласуется с теоретическим результатом Епанечникова о близкой эффективности всех симметричных ядер. (Справа) Фиксированное окно $h = \text{const}$ vs переменное $h(x) = \rho(x, x_{(k+1)})$: переменное стабильно лучше, выигрыш растёт с уровнем шума.




Рис. 8. Лучшая ядерная модель (epanechnikov, $h^* = 0,5$). (Слева) Предсказание vs истина на тесте. (Справа) Распределение остатков: симметричное, центрировано около нуля, легкие хвосты соответствуют дополнительным компонентам шума, не учтённым ядерной моделью.

5.5. Результаты: робастность LOWESS

Для оценки робастности в обучающую выборку искусственно вносится доля $\pi \in \{0; 0,03; 0,06; 0,10; 0,15; 0,20\}$ выбросов с амплитудой $\mathcal{N}(0, 1)$ (тогда как чистый шум $\sigma = 0,12$). Сравниваются Надарая--Ватсон и LOWESS, оба с оптимальной шириной окна.




Рис. 9. (Слева) Качественное сравнение на 1D-задаче с 10% выбросов: обычная NW <<затягивается>> к выбросам, тогда как LOWESS следует $\sin(x)$. (Справа) Финальные веса γ_i после сходимости итераций: для регулярных точек $\gamma_i \approx 1$, для выбросов --- около нуля. Распределение γ бимодально, как и ожидается от М-оценки Тьюки.




Рис. 10. Test RMSE как функция доли выбросов π в обучающей выборке (1D-синтетика). С ростом загрязнения NW теряет качество монотонно; LOWESS остаётся устойчивым до $\pi \approx 0,2$, после чего тоже деградирует, но менее резко.

Таблица 4. Test RMSE на 1D-синтетике в зависимости от доли выбросов π в обучении. Жирным выделено, где LOWESS статистически лучше NW.

π	NW RMSE	LOWESS RMSE	Выигрыш
0,00	0,143	0,142	≈ 0
0,03	0,221	0,176	+20%
0,06	0,608	0,620	≈ 0
0,10	0,705	0,717	≈ 0
0,15	0,845	0,794	+6%
0,20	1,198	1,191	≈ 0

5.6. Результаты: реальные табличные датасеты




Рис. 11. Сравнение трёх метрических методов на двух табличных датасетах. Столбцы --- test MAE, RMSE и R^2 . NW с переменным окном даёт наилучшее R^2 на *California Housing*; LOWESS на чистых данных без выбросов проигрывает обоим вариантам NW.

Таблица 5. Метрические методы на табличных датасетах. Стандартизация признаков по обучающей части, train/test = 75/25.

Датасет	Модель	MAE	RMSE	R^2
Diabetes ($\bar{y} = 152, \sigma_y = 77$)	NW fixed	47,6	57,9	0,460
	NW variable	46,4	58,2	0,454
	LOWESS	48,7	59,6	0,427
California ($\bar{y} = 2,07, \sigma_y = 1,16, \times 10^5 \$$)	NW fixed	0,488	0,679	0,644
	NW variable	0,491	0,674	0,649
	LOWESS	0,508	0,720	0,600

На обоих датасетах переменное окно даёт небольшой устойчивый выигрыш над фиксированным. На *California Housing* это выражено заметнее --- плотность облака признаков сильно неоднородна (кластеры пригородов и городские агломерации), и адаптивная ширина окна выгоднее. LOWESS на чистых данных проигрывает обычной Надарая--Ватсону: за робастность приходится платить небольшим ухудшением метрик в отсутствие выбросов [14].

6. Обсуждение

6.1. Согласие эксперимента с теорией

Эмпирическое наблюдение о доминировании выбора h над выбором ядра прямо вытекает из асимптотической формулы (2): h определяет порядок сходимости $\ell^{-2/5}$, а K --- лишь постоянную. Размах LOO RMSE при изменении h ($\Delta \approx 0,018$) против $\Delta \approx 0,003$ при смене ядра --- количественное подтверждение этого положения. Эпанечниковский оптимум [9] даёт лишь несколько процентов выигрыша по асимптотической MSE, что эмпирически наблюдается как малость Δ .

На реальных табличных датасетах достигнутые качества согласуются с известными бенчмарками: на *Diabetes* линейная регрессия даёт $R^2 \approx 0,45--0,50$ [4], что соответствует полученному значению $R^2 = 0,460$ для NW. Это означает, что при невысокой размерности ($d = 10$) ядерная регрессия конкурентоспособна по сравнению с параметрическими моделями. На *California Housing* ($d = 8, n = 3000$) $R^2 = 0,65$ уступает gradient boosting ($R^2 \approx 0,83$), что объяснимо: ядерные методы не используют тонкой структуры взаимодействий признаков, которую улавливают деревья.

6.2. Связь с функциональным анализом

С точки зрения функционального анализа оба подхода работают над одним и тем же конечномерным проектированием функции x на конечную систему $\{\varphi_k\}_{k=1}^m \subset L_2[0, 1]$. В линейной модели результат

проектирования участвует в скалярном произведении с восстановленной функцией $w(t) \in L_2[0, 1]$. В метрической модели --- в евклидовом расстоянии в $\mathbb{R}^m$. Качество в обоих случаях в первую очередь определяется тем, насколько $\{\varphi_k\}$ согласована с истинной структурой x : индикаторный базис не способен эффективно представить $\sin(2\pi t)$, а тригонометрический --- именно для этого создан.

Можно также заметить, что весовая функция $w(t)$ из подраздела 3.5 --- это ядро интегрального оператора $T_w: L_2[0, 1] \rightarrow \mathbb{R}$, $T_w(x) = \langle x, w \rangle + \beta_0$, который по теореме Рисса 1 *единственным* образом задаёт линейную часть модели. Таким образом, обучение линейной регрессии по функциональным признакам и подбор w эквивалентны с точностью до выбора подпространства $\text{span}\{\varphi_k\}$.

6.3. Ограничения работы

1. Все эксперименты с табличными датасетами выполнены при размерности $d \leq 10$; теоретическое <<проклятие размерности>> $n^{-2/(4+d)}$ делает чистый Надарая--Ватсон практически непригодным при $d \gtrsim 10$ без понижения размерности. Это видно по падению качества с ростом признаков, не вошедшему в основной отчёт.
2. Используется только локальный полином степени 0 (NW); локально-линейная регрессия (LOESS первого порядка) часто даёт меньшее граничное смещение, но это выходит за рамки задания.
3. Для LOWESS не реализована стратегия адаптивного h в зависимости от итерации (например, схема trifold у Cleveland & Devlin [13]); это могло бы дополнительно стабилизировать веса в больших выборках.
4. Эксперименты проведены при фиксированном $\text{seed} = 42$; полноценное бутстрап-усреднение для доверительных интервалов метрик не делалось --- в задании это не требовалось.

6.4. Сравнение подходов

Таблица 6. Сводное сопоставление двух семейств методов по основным критериям.

Критерий	Линейная по функционалам	Метрическая (NW/LOWESS)
Интерпретируемость	Глобальная через $w(t)$	Локальная, в окрестности x
Обучение	$O(nm^2 + m^3)$	Отсутствует (lazy)
Инференс	$O(m)$	$O(\ell)$ для NW, $O(\ell T)$ для LOWESS
Гипотеза о форме	Линейность по φ_k	Непрерывность $\mathbb{E}[y x]$
Поведение при $d \gg 1$	Стабильно	Проседает ($n^{-2/(4+d)}$)
Робастность к выбросам	Слабая (ridge помогает мало)	LOWESS --- основная сила
Экстраполяция	Возможна (линейный продолж.)	Деградирует к среднему

7. Заключение

В работе предложена и реализована единая схема регрессионного анализа, в которой функциональные данные через применение интегральных линейных функционалов превращаются в конечно-мерное представление, после чего к этому представлению применяются как параметрические (МНК, ridge), так и непараметрические (Надарая--Ватсон, LOWESS) методы.

Получены следующие основные результаты.

1. Для синтетических функциональных данных тригонометрический базис из $m = 9$ функционалов восстанавливает истинную весовую функцию $w(t) = 2 \sin(2\pi t) - t$ с test RMSE 0,094 и $R^2 = 0,993$; полиномиальный и индикаторный базисы существенно хуже из-за несогласованности с периодической структурой целевой переменной.
2. Эмпирически и аналитически подтверждено, что выбор ширины окна h влияет на качество Надарая--Ватсона на порядок сильнее, чем выбор ядра ($\Delta \text{RMSE}_h / \Delta \text{RMSE}_K \approx 6$), в полном соответствии с асимптотическим разложением (2).
3. Переменное окно $h(x) = \rho(x, x_{(k+1)})$ стабильно даёт небольшой выигрыш на неоднородно распре-

делённых данных (*California Housing*: $R^2 = 0,649$ против $0,644$ у фиксированного).

4. Робастная схема LOWESS становится строго лучше Надарая--Ватсона начиная с доли выбросов $\sim 3\%$ (test RMSE $0,176$ против $0,221$); на чистых данных платится $\sim 2\text{--}3\%$ качества за устойчивость.

В качестве направлений дальнейшего развития естественным шагом видятся: переход к локально-линейной (LOESS) и локально-квадратичной регрессии для снижения граничного смещения; использование адаптивных к плотности признаков метрик (Mahalanobis, метрик в воспроизводящих ядерных гильбертовых пространствах); расширение функциональной части на негладкие сигналы через B-сплайновые и вейвлетные базисы.

Код и воспроизводимость

Полный исходный код, тесты (включая регрессионный тест на edge-case LOWESS с константным откликом), скрипты сборки графиков и таблиц (`build_report_assets.py`) и LaTeX-источник этого отчёта опубликованы в открытом репозитории:

https://github.com/paulhowever/funkan_tischenko_j3210

Все эксперименты воспроизводимы по фиксированному `seed = 42`; одна команда `python build_report_assets.py` пересобирает все 19 рисунков и 10 таблиц, фигурирующих в отчёте.

Литература

- [1] M. Reed, B. Simon, *Methods of Modern Mathematical Physics. I: Functional Analysis*, Academic Press, 1980.
- [2] P. D. Lax, *Functional Analysis*, Wiley-Interscience, 2002.
- [3] A. E. Hoerl, R. W. Kennard, *Ridge regression: biased estimation for nonorthogonal problems*, Technometrics 12 (1970) 55--67.
- [4] T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning*, 2nd ed., Springer, 2009.
- [5] C. Stein, *Estimation of the mean of a multivariate normal distribution*, Annals of Statistics 9 (1981) 1135--1151.
- [6] E. A. Nadaraya, *On estimating regression*, Theory Probab. Appl. 9 (1964) 141--142.
- [7] G. S. Watson, *Smooth regression analysis*, Sankhyā A 26 (1964) 359--372.
- [8] E. Parzen, *On estimation of a probability density function and mode*, Ann. Math. Stat. 33 (1962) 1065--1076.
- [9] V. A. Epanechnikov, *Non-parametric estimation of a multivariate probability density*, Theory Probab. Appl. 14 (1969) 153--158.
- [10] C. J. Stone, *Optimal rates of convergence for nonparametric estimators*, Ann. Stat. 8 (1980) 1348--1360.
- [11] M. P. Wand, M. C. Jones, *Kernel Smoothing*, Chapman & Hall, 1995.
- [12] W. S. Cleveland, *Robust locally weighted regression and smoothing scatterplots*, J. Amer. Statist. Assoc. 74 (1979) 829--836.
- [13] W. S. Cleveland, S. J. Devlin, *Locally weighted regression: an approach to regression analysis by local fitting*, J. Amer. Statist. Assoc. 83 (1988) 596--610.
- [14] P. J. Huber, E. M. Ronchetti, *Robust Statistics*, 2nd ed., Wiley, 2009.