

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**

**Федеральное государственное автономное образовательное учреждение
высшего образования**

<<Национальный исследовательский университет ИТМО>>

Факультет технологий искусственного интеллекта

Лабораторная работа

по дисциплине
<<Функциональный анализ>>

**Регрессия по функциональным данным:
линейные функционалы и метрические методы**

Кейсы №4 и №6

Выполнил:
студент группы J3210
Тищенко Павел Валерьевич

Исходный код: https://github.com/paulhowever/funkan_tischenko_j3210

Санкт-Петербург, 2026

1. Введение

В прикладных задачах объект наблюдения часто задаётся не вектором, а функцией $x(t)$, $t \in [0, 1]$ (временной ряд, сигнал датчика, профиль и т. п.). По функции требуется предсказать число $y \in \mathbb{R}$.

Работа объединяет два подхода к этой задаче в одну схему:

$$x(t) \xrightarrow{\text{кейс 4}} z = (\langle x, \varphi_1 \rangle, \dots, \langle x, \varphi_m \rangle) \xrightarrow{\text{кейс 6}} \hat{y}.$$

Кейс 4 — параметрический подход: функция превращается в конечномерный вектор линейных функционалов, на котором обучается линейная (или ridge) регрессия; восстанавливается весовая функция $w(t)$.

Кейс 6 — непараметрические метрические методы: ядерная регрессия Надарая--Ватсона с фиксированным и переменным окном, а также робастная схема LOWESS. Эти методы применены и к признакам кейса 4, и к двум табличным датасетам --- *Diabetes* и *California Housing*.

2. Данные

Синтетические функциональные данные:

$$x_i(t) = a_i \sin(2\pi t) + b_i \cos(2\pi t) + c_i t + \varepsilon_i(t), \quad y_i = 2 \int_0^1 x_i(t) \sin(2\pi t) dt - \int_0^1 x_i(t) t dt + \eta_i.$$

Истинная зависимость линейна по интегральным функционалам, шум функции ε_i и шум ответа η_i — нормальные.

Реальные датасеты: *Diabetes* (sklearn, $n = 442$, 10 признаков, целевая — индекс прогрессирования заболевания) и *California Housing* (под-выборка $n = 3000$ из 20640, 8 признаков, медианная цена дома в $\$10^5$). Признаки стандартизуются на обучающей части (z-score) — без этого метрический метод деградирует из-за разного масштаба компонент.




Рис. 1. Примеры сгенерированных функциональных данных $x_i(t)$.

3. Кейс 4. Линейные функционалы и регрессия

3.1. Признаки через линейные функционалы

Признаки строятся как

$$z_{ik} = L_{\varphi_k}(x_i) = \int_0^1 x_i(t) \varphi_k(t) dt = \langle x_i, \varphi_k \rangle.$$

В $L_2[0, 1]$ это скалярное произведение, поэтому функционал измеряет согласованность x_i с шаблоном φ_k . Линейность сразу следует из линейности интеграла:

$$L_\varphi(\alpha x + \beta y) = \int (\alpha x + \beta y) \varphi dt = \alpha L_\varphi(x) + \beta L_\varphi(y).$$

Численная проверка для конкретной пары функционалов даёт абсолютную разницу левой и правой частей $\sim 10^{-9}$ (см. `tables/linearity_check.csv`).

Сравниваются три системы:

- **индикаторы** $\mathbf{1}_{[\tau_{k-1}, \tau_k]}(t)$ — локальные средние;
- **полиномы** $1, t, t^2, \dots, t^{m-1}$ — гладкие тренды;
- **тригонометрический базис** $1, \sin(2\pi t), \cos(2\pi t), \sin(4\pi t), \dots$ — периодические компоненты.

Интегралы вычисляются по формуле трапеций на сетке $N = 320$.

3.2. Линейная и ridge-регрессия

После добавления столбца единиц для свободного члена модель — $\hat{y} = X\beta$. МНК-оценка получается из нормальных уравнений

$$X^T X \hat{\beta} = X^T y \implies \hat{\beta} = (X^T X)^{-1} X^T y,$$

ridge с штрафом $\lambda \|\beta\|^2$ — из $(X^T X + \lambda I) \hat{\beta}_\lambda = X^T y$.

Линейную модель удобно записать через *весовую функцию* $w(t) = \sum_k \beta_k \varphi_k(t)$: $\hat{y}(x) = \beta_0 + \langle x, w \rangle$. Функция $w(t)$ показывает, какие участки $x(t)$ сильнее влияют на прогноз.




Рис. 2. Слева: восстановленные $w(t)$ для трёх базисов. Справа: лучший test RMSE по каждому базису.

3.3. Эксперименты

Метрики: $\text{MAE} = \frac{1}{n} \sum |y_i - \hat{y}_i|$, $\text{RMSE} = \sqrt{\text{MSE}}$, $R^2 = 1 - \text{SS}_{\text{res}}/\text{SS}_{\text{tot}}$. Train/test делятся 75/25.





Рис. 3. Слева: зависимость test RMSE от числа функционалов m . Справа: зависимость test RMSE от λ (ridge).

Таблица 1. Лучшая линейная модель на синтетических данных.

Конфигурация	test RMSE	test MAE	test R^2
Тригонометрический, $m = 3$, $\lambda = 0$	~ 0.11	~ 0.07	~ 0.99
Лучший индикаторный, $m \approx 11$	~ 0.40	~ 0.30	~ 0.90
Лучший полиномиальный, $m \approx 5$	~ 0.55	~ 0.40	~ 0.80

Тригонометрический базис ожидаемо побеждает: целевая переменная задана через $\sin(2\pi t)$ и t , и функционалы напрямую согласованы с этой структурой. Оптимальное $m = 3$ (большее не уменьшает test RMSE, а train продолжает падать — переусложнение). Оптимальное λ близко к нулю: при малом m модель уже хорошо обусловлена.




Рис. 4. Лучшая линейная модель: истинные vs предсказанные y и распределение остатков.

4. Кейс 6. Метрические методы

4.1. Надарая--Ватсон

В предположении гипотезы непрерывности (близкие x дают близкие y) оценка строится как локально взвешенное среднее:

$$a(x; X^\ell, h) = \frac{\sum_i y_i K(\rho(x, x_i)/h)}{\sum_i K(\rho(x, x_i)/h)}.$$

Это решение задачи WLS с локальной константной моделью $f(x_i) \approx \theta$: производная $\sum w_i(\theta - y_i) = 0$ даёт ровно эту формулу.

Окно. Фиксированное: $h = \text{const}$. Переменное: $h(x) = \rho(x, x_{(k+1)})$ — окно адаптируется к плотности данных.

Ядра. Сравниваются гауссовское $\frac{1}{\sqrt{2\pi}}e^{-r^2/2}$, треугольное $(1-|r|)\mathbf{1}_{|r|\leq 1}$, Епанечникова $\frac{3}{4}(1-r^2)\mathbf{1}_{|r|\leq 1}$ и кватрическое $\frac{15}{16}(1-r^2)^2\mathbf{1}_{|r|\leq 1}$.

Подбор h, k , ядра — по leave-one-out RMSE (важно: не по тестовой выборке, иначе оценка качества смещена оптимистично):

$$\text{LOO RMSE} = \sqrt{\frac{1}{\ell} \sum_i (y_i - \hat{y}_i^{(-i)})^2}.$$

4.2. Эксперименты на одномерной синтетике

Задача $y = \sin x + \varepsilon$ позволяет визуально оценить роль h .





Рис. 5. 1D синтетика $y = \sin x + \varepsilon$. Слева: NW при разных h (малое h — переобучение, большое — пересглаживание). Справа: классическая U-shape RMSE(h).





Рис. 6. LOO RMSE для четырёх ядер: слева от h , справа от k .




Рис. 7. Слева: лучшая модель по каждому ядру — все ядра почти не отличаются. Справа: фиксированное vs переменное окно.




Рис. 8. Лучшая ядерная модель: предсказание и распределение остатков.

4.3. Качество на реальных датасетах

Таблица 2. Метрические методы на реальных датасетах (стандартизованные признаки, train/test = 75/25).

Датасет	Модель	MAE	RMSE	R^2
Diabetes	NW fixed	47.6	57.9	0.460
Diabetes	NW variable	46.4	58.2	0.454
Diabetes	LOWESS	48.7	59.6	0.427
California	NW fixed	0.488	0.679	0.644
California	NW variable	0.491	0.674	0.649
California	LOWESS	0.508	0.720	0.600

5. Робастная схема LOWESS

LOWESS итеративно перевзвешивает объекты, понижая вклад тех, где модель ошибается сильно. На каждой итерации:

$$a_i = \frac{\sum_{j \neq i} y_j \gamma_j K(\rho(x_i, x_j)/h(x_i))}{\sum_{j \neq i} \gamma_j K(\rho(x_i, x_j)/h(x_i))}, \quad \gamma_i = \tilde{K}\left(\frac{|a_i - y_i|}{6 \operatorname{med}\{\varepsilon\}}\right),$$

где $\tilde{K}$ — биквадратное (квартическое) ядро. Объекты с $|a_i - y_i| > 6 \operatorname{med}\{\varepsilon\}$ получают $\gamma_i = 0$ — то есть полностью игнорируются.




Рис. 9. Слева: NW и LOWESS на 1D с выбросами — обычная NW искажена выбросами, LOWESS их игнорирует. Справа: финальные γ_i — для выбросов значения близки к 0.




Рис. 10. Test RMSE как функция доли выбросов. С ростом загрязнения NW резко теряет качество, LOWESS остаётся устойчивым.

6. Итоги

6.1. Сравнение подходов

Линейная модель по функциональным признакам *интерпретируема* через $w(t)$ и на сгенерированных данных, где истинная зависимость линейна по интегральным функционалам, даёт $R^2 \approx 0.99$. Метрические методы более *гибкие* и не требуют формы зависимости, но сильнее зависят от выбора метрики и параметров. На реальных задачах (*Diabetes*, *California*) они достигают $R^2 \approx 0.46$ и 0.65 . Ridge стабилизирует линейную модель, LOWESS — метрическую при выбросах.

6.2. Ответы на исследовательские вопросы кейса 6

(1) **Что важнее — ядро или ширина окна?** Ширина окна. Размах LOO RMSE при изменении h составил ~ 0.018 , а при смене ядра при фиксированном h — ~ 0.003 , то есть в 5–6 раз меньше. Это согласуется с теорией Парзена–Розенблатта: h задаёт скорость сходимости $n^{-4/5}$, ядро — лишь константу.

(2) **Когда переменное окно выигрывает?** При неоднородной плотности $p(x)$. На равномерной 1D-синтетике выигрыш ~ 1 –2%; на *California Housing* (плотность признакового облака сильно неоднородна) — R^2 0.649 против 0.644.

(3) **При какой доле выбросов LOWESS лучше?** Уже от $\sim 3\%$ выбросов LOWESS заметно лучше (test RMSE 0.176 vs 0.221 у NW). На полностью чистых данных платится ~ 2 –3%

качества за робастность; начиная с ~ 6 --10% загрязнения LOWESS строго лучше.

6.3. Воспроизводимость

Весь код, тесты и скрипт регенерации артефактов:

https://github.com/paulhowever/funkan_tischenko_j3210

Сборка отчёта с нуля:

```
pip install -e .
PYTHONPATH=src python3 build_report_assets.py # генерирует фигуры и таблицы
tectonic report.tex                          # либо xelatex / pdflatex
```