

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**

**Федеральное государственное автономное образовательное учреждение
высшего образования**

<<Национальный исследовательский университет ИТМО>>

Факультет технологий искусственного интеллекта

Лабораторная работа

по дисциплине

<<Функциональный анализ>>

**Регрессия по функциональным данным:
линейные функционалы и метрические методы**

Кейсы №4 и №6

Выполнил:

студент группы J3210

Тищенко Павел Валерьевич

Санкт-Петербург

2026

Содержание

Аннотация	4
Введение	5
1 Постановка задачи регрессии по функциональным данным	7
1.1 Функциональные данные	7
1.2 Дискретизация функций	8
1.3 Связь кейса 4 и кейса 6	8
2 Описание данных	9
2.1 Синтетические функциональные данные	9
2.2 Реальные датасеты	10
3 Построение признаков с помощью линейных функционалов	11
3.1 Понятие линейного функционала	11
3.2 Проверка линейности функционала	12
3.3 Системы функций для построения признаков	12
3.3.1 Индикаторы подотрезков	13
3.3.2 Тригонометрический базис	13
3.3.3 Полиномиальный базис	14
3.4 Численное вычисление интегралов	14
4 Линейная регрессия по функциональным признакам	15
4.1 Модель линейной регрессии	15
4.2 Матричная форма модели	15
4.3 Метод наименьших квадратов	16
4.4 Ridge-регрессия	16
4.5 Восстановление весовой функции	17
5 Экспериментальное исследование линейной модели	18
5.1 Сравнение систем функционалов	18
5.2 Влияние числа функционалов	19
5.3 Влияние регуляризации	21

5.4	Анализ прогнозов и ошибок	21
5.5	Численный итог по линейной модели	23
6	Метрические методы регрессии	23
6.1	Гипотеза непрерывности	23
6.2	Метрика в пространстве признаков	24
6.3	Ядерная регрессия Надарая--Ватсона	24
6.4	Связь с локально взвешенным методом наименьших квадратов	25
6.5	Фиксированная и переменная ширина окна	26
6.6	Ядерные функции	26
6.7	Подбор параметров	27
7	Экспериментальное исследование метрических методов	28
7.1	Одномерная иллюстрация ядерного сглаживания	28
7.2	Влияние ширины окна	29
7.3	Влияние числа соседей	30
7.4	Сравнение ядер	30
7.5	Сравнение фиксированного и переменного окна	31
7.6	Анализ прогнозов и ошибок ядерной модели	31
7.7	Качество на реальных датасетах	32
8	Робастная регрессия LOWESS	33
8.1	Идея метода	33
8.2	Исследование устойчивости к выбросам	34
8.3	Финальные веса LOWESS	34
8.4	Одномерная иллюстрация LOWESS	35
9	Сравнение линейного и метрического подходов	35
9.1	Ответы на исследовательские вопросы кейса 6	37
9.2	Смысловая интерпретация результатов	38
	Заключение	39
	Список использованных источников	40
A	Дополнительные материалы эксперимента	41

Аннотация

В работе рассматривается задача регрессии по функциональным данным, когда объект наблюдения задаётся не конечномерным вектором признаков, а функцией одной переменной на фиксированном интервале.

Сначала исходные функции преобразуются в конечномерные векторы признаков с помощью линейных функционалов интегрального вида. На полученных признаках строится линейная регрессионная модель, исследуется влияние выбора системы функционалов, числа признаков и регуляризации на качество прогноза. Лучшая параметрическая модель в проведённых экспериментах достигает test RMSE порядка 0,11 и R^2 около 0,99 на синтетических функциональных данных.

Далее те же функциональные признаки рассматриваются как элементы метрического пространства. На их основе реализуются метрические методы регрессии: ядерная регрессия Надарая--Ватсона с фиксированным и переменным окном, а также робастная схема LOWESS. Качество измеряется на синтетической одномерной задаче, на датасете <<Diabetes>> и на под-выборке <<California Housing>>.

Цель работы состоит в сравнении параметрического подхода, основанного на линейных функционалах, и непараметрического метрического подхода с точки зрения качества прогноза, устойчивости к шуму и выбросам, а также интерпретируемости модели.

Введение

Во многих прикладных задачах объект наблюдения естественно задаётся не конечномерным вектором признаков, а функцией одной переменной. К таким данным относятся временные ряды, сигналы датчиков, профили нагрузки, суточные температурные кривые, ЭКГ-сигналы и другие объекты, наблюдаемые на фиксированном интервале.

В данной работе рассматривается задача регрессии по функциональным данным. Пусть каждому объекту соответствует функция $x(t)$, заданная на интервале $[a, b]$, а целевой переменной является число $y \in \mathbb{R}$. Требуется построить модель, позволяющую по функции $x(t)$ предсказывать значение y .

Первый подход основан на использовании линейных функционалов. Исходная функция преобразуется в конечномерный вектор признаков с помощью интегралов вида

$$L_\varphi(x) = \int_a^b x(t)\varphi(t) dt,$$

где $\varphi(t)$ — заранее выбранная весовая функция. После такого преобразования задача сводится к обычной регрессии по числовым признакам.

Второй подход основан на метрических методах регрессии. Полученные функциональные признаки рассматриваются как точки в конечномерном метрическом пространстве. Для построения прогноза используются расстояния между объектами, ядерное сглаживание Надарая--Ватсона, переменная ширина окна и робастная схема LOWESS.

Таким образом, кейс 4 и кейс 6 объединяются в единую исследовательскую схему. В кейсе 4 строится конечномерное представление функциональных данных, а в кейсе 6 на этом представлении (а также на стандартных табличных датасетах <<Diabetes>> и <<California Housing>>) применяются метрические методы регрессии. Это позволяет сравнить параметрический и непараметрический подходы к одной и той же задаче и оценить роль каждого блока в итоговом качестве.

Цель работы — реализовать и сравнить методы регрессии по функциональным данным на основе линейных функционалов и метрического сглаживания.

Для достижения цели необходимо решить следующие задачи:

1. задать пространство функциональных данных и способ их дискретного представления;
2. построить признаки с помощью нескольких систем линейных функционалов;
3. реализовать линейную регрессию по функциональным признакам;
4. исследовать влияние выбора функционалов и их количества на качество прогноза;
5. восстановить и проанализировать весовую функцию линейной модели;
6. реализовать ridge-регрессию и исследовать влияние регуляризации;
7. реализовать ядерную регрессию Надарая--Ватсона с фиксированным и переменным окном;
8. реализовать робастную схему LOWESS;
9. оценить качество моделей по метрикам MAE, MSE, RMSE и R^2 как на синтетике, так и на двух реальных датасетах;
10. исследовать устойчивость моделей к шуму, выбросам и изменению параметров.

1. Постановка задачи регрессии по функциональным данным

1.1. Функциональные данные

В классических задачах машинного обучения объект обычно представляется конечномерным вектором признаков:

$$x_i = (x_{i1}, x_{i2}, \dots, x_{in}) \in \mathbb{R}^n.$$

Однако во многих задачах объект имеет более сложную природу и задаётся функцией:

$$x_i(t), \quad t \in [a, b].$$

Например, если объектом является суточная температура, то t может обозначать время в течение суток, а $x_i(t)$ — значение температуры в момент времени t . Если объектом является сигнал датчика, то $x_i(t)$ описывает изменение сигнала во времени.

В данной работе рассматриваются функции, определённые на отрезке

$$[a, b] = [0, 1].$$

Требуется по функции $x_i(t)$ предсказать числовой ответ

$$y_i \in \mathbb{R}.$$

Иными словами, необходимо построить отображение

$$x_i(t) \mapsto y_i.$$

Пояснение. Главная сложность состоит в том, что функция — это бесконечномерный объект. Даже если она хранится на сетке, математически она описывает целую кривую, а не один обычный вектор. Поэтому сначала нужно получить из функции конечное число признаков.

1.2. Дискретизация функций

На практике функция $x_i(t)$ хранится не как непрерывный объект, а как набор значений на сетке:

$$t_0, t_1, \dots, t_{N-1}.$$

В работе используется равномерная сетка:

$$t_j = a + j\Delta t, \quad j = 0, 1, \dots, N - 1,$$

где

$$\Delta t = \frac{b - a}{N - 1}.$$

Тогда функция $x_i(t)$ представляется в виде набора значений:

$$x_i(t_0), x_i(t_1), \dots, x_i(t_{N-1}).$$

Такое представление позволяет численно вычислять интегралы и строить функциональные признаки.

1.3. Связь кейса 4 и кейса 6

Кейс 4 посвящён построению регрессии по функциональным данным через линейные функционалы. В нём исходная функция $x_i(t)$ преобразуется в вектор признаков:

$$z_i = (z_{i1}, z_{i2}, \dots, z_{im}),$$

где

$$z_{ik} = \int_0^1 x_i(t) \varphi_k(t) dt.$$

Кейс 6 посвящён метрическим методам регрессии. В нём предполагается, что объекты являются векторами:

$$x_i \in \mathbb{R}^n.$$

В рамках общей схемы работы кейс 6 применяется к двум типам входных данных. Во-первых, к признаковому представлению, полученному в кейсе 4, то есть к векторам z_i функциональных признаков. Во-вторых, к таблич-

ным реальным датасетам <<Diabetes>> и <<California Housing>>, что позволяет проверить общность метода на стандартных задачах регрессии.

Общая схема имеет вид:

$$x_i(t) \longrightarrow z_i = \left(\int_0^1 x_i(t) \varphi_1(t) dt, \dots, \int_0^1 x_i(t) \varphi_m(t) dt \right) \longrightarrow \hat{y}_i.$$

Пояснение. Именно поэтому два кейса можно объединить в один отчёт. Кейс 4 отвечает за переход от функций к признакам, а кейс 6 использует эти признаки (или признаки реальных табличных датасетов) как метрическое пространство, где можно считать расстояния между объектами.

2. Описание данных

В работе используются три источника данных. Первый — синтетические функциональные данные, на которых проверяется кейс 4 и часть кейса 6. Второй и третий — стандартные табличные датасеты для задач регрессии: <<Diabetes>> из библиотеки scikit-learn и под-выборка из <<California Housing>>. Признаки реальных датасетов стандартизуются, что важно для метрических методов: иначе компонент с большим масштабом доминирует в евклидовом расстоянии.

2.1. Синтетические функциональные данные

Каждая функция имеет вид:

$$x_i(t) = a_i \sin(2\pi t) + b_i \cos(2\pi t) + c_i t + \varepsilon_i(t), \quad t \in [0, 1],$$

где a_i, b_i, c_i — случайные коэффициенты, а $\varepsilon_i(t)$ — шум функции с нулевым средним.

Целевой ответ задаётся формулой:

$$y_i = 2 \int_0^1 x_i(t) \sin(2\pi t) dt - \int_0^1 x_i(t) t dt + \eta_i,$$

где η_i — шум в ответе.

Такой способ генерации данных удобен тем, что истинная зависимость отклика от функции задаётся через линейные функционалы. Поэтому можно проверить, насколько хорошо разные системы функционалов и разные методы регрессии восстанавливают эту зависимость.

Пояснение. Функция $x_i(t)$ содержит синусоидальную, косинусоидальную и линейную компоненты. Поэтому ожидается, что тригонометрический базис должен хорошо описывать такие данные, так как он напрямую связан с синусами и косинусами.




Рис. 1. Примеры сгенерированных функциональных данных

2.2. Реальные датасеты

Кроме синтетики, для оценки метрических методов используются два классических датасета:

- **Diabetes** (sklearn, $n = 442$, 10 признаков, целевая переменная — индекс прогрессирования заболевания через год после базовых измерений). Признаки имеют разный физический смысл и масштаб, поэтому стандартизация особенно полезна.
- **California Housing** (sklearn, под-выборка из 20640, берётся 3000 случайных объектов, 8 признаков, целевая — медианная цена дома в районе в 10^5 долларов). Признаки имеют существенно разные масштабы (от

долей до тысяч), без стандартизации метрический метод сильно теряет в качестве.

Описание всех использованных наборов данных приведено в файле `report_outputs/tables/dataset_description.csv`.

3. Построение признаков с помощью линейных функционалов

3.1. Понятие линейного функционала

Функционалом называется отображение, которое каждой функции сопоставляет число. В данной работе используются интегральные функционалы вида

$$L_{\varphi}(x) = \int_0^1 x(t)\varphi(t) dt,$$

где $\varphi(t)$ — фиксированная весовая функция.

Если рассматривать пространство $L_2[0, 1]$, то выражение

$$\int_0^1 x(t)\varphi(t) dt$$

можно понимать как скалярное произведение функций $x(t)$ и $\varphi(t)$:

$$L_{\varphi}(x) = \langle x, \varphi \rangle.$$

Пояснение. Простыми словами, функционал измеряет, насколько функция $x(t)$ согласована с некоторым шаблоном $\varphi(t)$. Если $\varphi(t)$ — синус, то функционал показывает, насколько сильно в функции $x(t)$ выражена синусоидальная компонента.

3.2. Проверка линейности функционала

Функционал L_φ называется линейным, если для любых функций $x(t)$, $y(t)$ и любых чисел $\alpha, \beta \in \mathbb{R}$ выполняется:

$$L_\varphi(\alpha x + \beta y) = \alpha L_\varphi(x) + \beta L_\varphi(y).$$

Проверим это свойство:

$$L_\varphi(\alpha x + \beta y) = \int_0^1 (\alpha x(t) + \beta y(t)) \varphi(t) dt.$$

По линейности интеграла:

$$L_\varphi(\alpha x + \beta y) = \alpha \int_0^1 x(t) \varphi(t) dt + \beta \int_0^1 y(t) \varphi(t) dt.$$

Следовательно,

$$L_\varphi(\alpha x + \beta y) = \alpha L_\varphi(x) + \beta L_\varphi(y).$$

Значит, функционал L_φ является линейным. Численная проверка этого равенства на одной из синтетических функций сохранена в файле `report_outputs/tables/linearity_check.csv`; абсолютная разница между левой и правой частями составляет порядка 10^{-9} , что подтверждает корректность реализации.

Пояснение. Это свойство важно, потому что линейные функционалы сохраняют линейную структуру пространства функций. Если функция является линейной комбинацией двух других функций, то значение функционала также раскладывается в такую же линейную комбинацию.

3.3. Системы функций для построения признаков

Для построения признаков выбирается система функций:

$$\varphi_1(t), \varphi_2(t), \dots, \varphi_m(t).$$

Тогда для каждой функции $x_i(t)$ строится вектор:

$$z_i = (z_{i1}, z_{i2}, \dots, z_{im}),$$

где

$$z_{ik} = \int_0^1 x_i(t) \varphi_k(t) dt.$$

В работе рассматриваются три системы функционалов.

3.3.1. Индикаторы подотрезков

Первая система основана на индикаторах подотрезков:

$$\varphi_k(t) = \mathbf{1}_{[\tau_{k-1}, \tau_k]}(t).$$

Такие функционалы измеряют вклад функции на отдельных участках интервала.

Пояснение. Если интервал $[0, 1]$ разбить на несколько частей, то каждый функционал показывает, насколько велика функция на конкретном участке. Это похоже на локальные средние значения функции.

3.3.2. Тригонометрический базис

Вторая система основана на тригонометрических функциях:

$$1, \sin(2\pi t), \cos(2\pi t), \sin(4\pi t), \cos(4\pi t), \dots$$

Такие функционалы измеряют периодические компоненты функции.

Пояснение. Тригонометрический базис особенно полезен, если функция содержит волны или периодические колебания. В нашем случае данные специально содержат $\sin(2\pi t)$ и $\cos(2\pi t)$, поэтому такой базис должен быть хорошо согласован с природой данных.

3.3.3. Полиномиальный базис

Третья система основана на степенных функциях:

$$1, t, t^2, \dots, t^{m-1}.$$

Такие функционалы измеряют связь функции с гладкими полиномиальными трендами.

Пояснение. Полиномиальный базис хорошо описывает плавные изменения функции. Однако если данные имеют ярко выраженные периодические компоненты, одних полиномов может быть недостаточно.

3.4. Численное вычисление интегралов

Поскольку функции заданы на дискретной сетке, интегралы вычисляются численно. В работе используется формула трапеций:

$$\int_0^1 x(t) \varphi_k(t) dt \approx \sum_{j=0}^{N-2} \frac{x(t_j) \varphi_k(t_j) + x(t_{j+1}) \varphi_k(t_{j+1})}{2} (t_{j+1} - t_j).$$

Таким образом, для каждой функции $x_i(t)$ и каждой весовой функции $\varphi_k(t)$ вычисляется числовой признак z_{ik} .

Пояснение. Метод трапеций заменяет площадь под графиком суммой площадей маленьких трапеций. Чем плотнее сетка, тем точнее приближается интеграл.

4. Линейная регрессия по функциональным признакам

4.1. Модель линейной регрессии

После построения признаков задача регрессии сводится к обычной линейной модели:

$$\hat{y}_i = \beta_0 + \sum_{k=1}^m \beta_k z_{ik}.$$

Здесь z_{ik} — значение k -го линейного функционала на функции $x_i(t)$, β_k — коэффициент модели, β_0 — свободный член.

Пояснение. На этом этапе функция уже заменена набором чисел. Поэтому можно применять обычную линейную регрессию, как в задачах с табличными данными.

4.2. Матричная форма модели

Обозначим через Z матрицу функциональных признаков:

$$Z = \begin{pmatrix} z_{11} & z_{12} & \dots & z_{1m} \\ z_{21} & z_{22} & \dots & z_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ z_{n1} & z_{n2} & \dots & z_{nm} \end{pmatrix}.$$

Добавим к ней столбец единиц для свободного члена и получим матрицу:

$$X = \begin{pmatrix} 1 & z_{11} & z_{12} & \dots & z_{1m} \\ 1 & z_{21} & z_{22} & \dots & z_{2m} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & z_{n1} & z_{n2} & \dots & z_{nm} \end{pmatrix}.$$

Тогда модель записывается в виде:

$$\hat{y} = X\beta.$$

4.3. Метод наименьших квадратов

Для оценки коэффициентов используется метод наименьших квадратов. Минимизируется функционал:

$$Q(\beta) = (y - X\beta)^T (y - X\beta).$$

Этот функционал равен сумме квадратов ошибок:

$$Q(\beta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

Найдём условие минимума. Производная по β равна:

$$\frac{\partial Q}{\partial \beta} = -2X^T(y - X\beta).$$

Приравнивая производную к нулю, получаем нормальные уравнения:

$$X^T X \hat{\beta} = X^T y.$$

Если матрица $X^T X$ обратима, то решение имеет вид:

$$\hat{\beta} = (X^T X)^{-1} X^T y.$$

Пояснение. Метод наименьших квадратов подбирает такие коэффициенты, чтобы предсказания модели были как можно ближе к истинным значениям. Квадраты ошибок используются для того, чтобы большие ошибки штрафовались сильнее.

4.4. Ridge-регрессия

При большом числе признаков или при сильной зависимости признаков друг от друга оценки МНК могут стать неустойчивыми. Для повышения устойчивости используется ridge-регрессия:

$$Q_\lambda(\beta) = (y - X\beta)^T (y - X\beta) + \lambda \|\beta\|_2^2,$$

где $\lambda \geq 0$ — параметр регуляризации.

Нормальные уравнения принимают вид:

$$(X^T X + \lambda I) \hat{\beta}_\lambda = X^T y.$$

Отсюда:

$$\hat{\beta}_\lambda = (X^T X + \lambda I)^{-1} X^T y.$$

Пояснение. Регуляризация добавляет штраф за слишком большие коэффициенты. Это помогает избежать ситуации, когда модель слишком сильно подстраивается под обучающие данные и плохо работает на новых объектах.

4.5. Восстановление весовой функции

Линейную модель можно записать в функциональной форме:

$$\hat{y}(x) = \beta_0 + \sum_{k=1}^m \beta_k \langle x, \varphi_k \rangle.$$

Введём функцию весов:

$$w(t) = \sum_{k=1}^m \beta_k \varphi_k(t).$$

Тогда:

$$\langle x, w \rangle = \left\langle x, \sum_{k=1}^m \beta_k \varphi_k \right\rangle.$$

По линейности скалярного произведения:

$$\left\langle x, \sum_{k=1}^m \beta_k \varphi_k \right\rangle = \sum_{k=1}^m \beta_k \langle x, \varphi_k \rangle.$$

Следовательно,

$$\hat{y}(x) = \beta_0 + \langle x, w \rangle.$$

Пояснение. Функция $w(t)$ показывает, какие участки исходной функции $x(t)$ сильнее влияют на прогноз. Если $w(t)$ велико по модулю на некотором участ-

ке, то значения функции $x(t)$ на этом участке особенно важны для модели.




Рис. 2. Сравнение восстановленных весовых функций

5. Экспериментальное исследование линейной модели

5.1. Сравнение систем функционалов

Для оценки качества разных систем функционалов были построены признаки на основе индикаторов подотрезков, тригонометрического базиса и полиномиального базиса. Для каждой системы обучалась линейная модель, после чего качество оценивалось на тестовой выборке.

Основными метриками качества являются:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|,$$

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

$$\text{RMSE} = \sqrt{\text{MSE}},$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

Пояснение. MAE показывает среднюю абсолютную ошибку. RMSE также измеряет ошибку, но сильнее штрафует большие отклонения. Метрика R^2 показывает, какую долю изменчивости целевой переменной объясняет модель.




Рис. 3. Сравнение качества разных систем функционалов

На рисунке 3 сравниваются системы функционалов по ошибке RMSE. Чем меньше значение RMSE, тем точнее модель восстанавливает зависимость между функцией $x(t)$ и ответом y . На рассмотренных синтетических данных тригонометрический базис ожидаемо оказывается лучшим: целевая переменная задана через интегралы со $\sin(2\pi t)$ и t , и тригонометрические функционалы напрямую согласованы с этой структурой.

5.2. Влияние числа функционалов

Следующий эксперимент связан с изменением числа функционалов m . При малом m модель может не получать достаточно информации о функции. При слишком большом m возрастает риск переобучения и неустойчивости коэффициентов.




Рис. 4. Зависимость ошибки от числа функционалов




Рис. 5. Влияние числа функционалов на обучение и обобщение

По графикам можно оценить баланс между недообучением и переобучением. Если ошибка на обучении уменьшается, а ошибка на тесте начинает расти, это указывает на переусложнение модели. На синтетических данных оптимальное число тригонометрических функционалов оказывается равным небольшому значению порядка $m = 3-5$: дальнейшее увеличение m практически не уменьшает test RMSE, а train RMSE продолжает падать.

5.3. Влияние регуляризации

Для исследования влияния регуляризации обучались ridge-модели при различных значениях параметра λ . Малые значения λ почти не отличаются от обычного МНК, а большие значения сильнее уменьшают коэффициенты модели.




Рис. 6. Зависимость качества ridge-регрессии от параметра регуляризации

Регуляризация полезна тогда, когда увеличение числа признаков делает модель неустойчивой. В этом случае штраф на норму коэффициентов позволяет получить более гладкое и устойчивое решение. На сгенерированной выборке оптимальное λ близко к нулю — это согласуется с тем, что лучшее число признаков уже мало ($m = 3\text{--}5$) и модель хорошо обусловлена.

5.4. Анализ прогнозов и ошибок

Для лучшей линейной модели были построены графики истинных и предсказанных значений, а также распределение остатков.




Рис. 7. Истинные и предсказанные значения для линейной модели

Если точки на рисунке 7 расположены близко к диагонали, значит модель хорошо предсказывает целевую переменную.




Рис. 8. Распределение ошибок линейной модели

Распределение остатков позволяет проверить, нет ли систематического смещения модели. Если ошибки сосредоточены около нуля, модель в среднем не завышает и не занижает прогноз.

5.5. Численный итог по линейной модели

В таблице 1 приведены численные итоги по лучшей конфигурации линейной модели на синтетических функциональных данных. Полные перебираемые конфигурации сохранены в файлах `linear_basis_comparison.csv` и `best_linear_models.csv`.

Таблица 1. Лучшая линейная модель на синтетических функциональных данных

Базис / параметры	test RMSE	test MAE	test R^2
Тригонометрический, $m = 3, \lambda = 0$	$\sim 0,11$	$\sim 0,07$	$\sim 0,99$
Лучший индикаторный, $m \approx 11$	$\sim 0,40$	$\sim 0,30$	$\sim 0,90$
Лучший полиномиальный, $m \approx 5$	$\sim 0,55$	$\sim 0,40$	$\sim 0,80$

6. Метрические методы регрессии

6.1. Гипотеза непрерывности

Метрические методы регрессии основаны на гипотезе непрерывности: близким объектам соответствуют близкие ответы.

В контексте данной работы объектом для метрической регрессии является либо признаковое представление синтетической функции

$$z_i = (z_{i1}, z_{i2}, \dots, z_{im}),$$

либо вектор признаков из табличных датасетов <<Diabetes>> и <<California Housing>>. Расстояния считаются между этими векторами.

Пояснение. После кейса 4 каждая функция уже превращена в точку в пространстве признаков. Если две функции похожи с точки зрения выбранных функционалов, то расстояние между их векторами z_i будет малым. Для табличных датасетов аналогично: близкие объекты в стандартизованном пространстве признаков должны иметь близкие ответы.

6.2. Метрика в пространстве признаков

В качестве расстояния между объектами используется евклидова метрика:

$$\rho(z, z_i) = \sqrt{\sum_{k=1}^m (z_k - z_{ik})^2}.$$

Здесь z — вектор признаков нового объекта, а z_i — вектор признаков объекта обучающей выборки.

Пояснение. Евклидово расстояние измеряет обычную геометрическую близость между точками. Для метрических методов важно масштабировать признаки, так как признаки большого масштаба могут начать доминировать в расстоянии. В данной работе для реальных датасетов применяется стандартизация (z-score) на обучающей части.

6.3. Ядерная регрессия Надарая--Ватсона

Оценка Надарая--Ватсона строит прогноз как взвешенное среднее ответов обучающих объектов:

$$a(z; X^\ell, h) = \frac{\sum_{i=1}^{\ell} y_i K\left(\frac{\rho(z, z_i)}{h}\right)}{\sum_{i=1}^{\ell} K\left(\frac{\rho(z, z_i)}{h}\right)}.$$

Здесь $K(r)$ — ядро, $h > 0$ — ширина окна, $\rho(z, z_i)$ — расстояние между объектами.

Чем ближе объект z_i к объекту z , тем больший вес получает его ответ y_i .

Пояснение. Прогноз получается не через одну глобальную формулу, как в линейной регрессии, а через локальное усреднение соседних объектов. Близкие объекты влияют на прогноз сильнее, дальние — слабее.

6.4. Связь с локально взвешенным методом наименьших квадратов

Оценку Надарая--Ватсона можно получить как решение задачи локально взвешенного метода наименьших квадратов при постоянной локальной модели:

$$f(z_i) \approx \theta.$$

Тогда минимизируется функционал:

$$Q(\theta; z) = \sum_{i=1}^{\ell} K \left(\frac{\rho(z, z_i)}{h} \right) (\theta - y_i)^2.$$

Обозначим

$$w_i = K \left(\frac{\rho(z, z_i)}{h} \right).$$

Тогда:

$$Q(\theta; z) = \sum_{i=1}^{\ell} w_i (\theta - y_i)^2.$$

Найдём минимум:

$$\frac{dQ}{d\theta} = 2 \sum_{i=1}^{\ell} w_i (\theta - y_i) = 0.$$

Отсюда:

$$\theta \sum_{i=1}^{\ell} w_i = \sum_{i=1}^{\ell} w_i y_i.$$

Следовательно,

$$\theta = \frac{\sum_{i=1}^{\ell} w_i y_i}{\sum_{i=1}^{\ell} w_i}.$$

Это и есть оценка Надарая--Ватсона.

Пояснение. Смысл вывода такой: мы ищем одно число θ , которое лучше всего описывает ответы ближайших объектов. Но ближайшие объекты учитываются с большими весами, а дальние — с малыми.

6.5. Фиксированная и переменная ширина окна

В случае фиксированного окна параметр h одинаков для всех объектов:

$$h = \text{const.}$$

При малом h модель становится более локальной и чувствительной к шуму. При большом h происходит сильное сглаживание, из-за чего модель может недообучаться.

Также рассматривается переменная ширина окна:

$$h(z) = \rho(z, z_{(k+1)}),$$

где $z_{(k+1)}$ — $(k + 1)$ -й ближайший сосед объекта z .

В этом случае ширина окна адаптируется к плотности данных: в плотных областях окно становится меньше, а в разреженных — больше.

Пояснение. Фиксированное окно использует один и тот же масштаб сглаживания везде. Переменное окно подстраивается под данные: если рядом много объектов, окно маленькое; если объектов мало, окно расширяется.

6.6. Ядерные функции

В работе сравниваются четыре ядерные функции.

Гауссовское ядро (бесконечный носитель):

$$K(r) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{r^2}{2}\right).$$

Треугольное ядро:

$$K(r) = (1 - |r|)\mathbf{1}_{|r| \leq 1}.$$

Ядро Епанечникова:

$$K(r) = \frac{3}{4}(1 - r^2)\mathbf{1}_{|r| \leq 1}.$$

Биквадратное (квартическое) ядро:

$$K(r) = \frac{15}{16}(1 - r^2)^2 \mathbf{1}_{|r| \leq 1}.$$

Пояснение. Ядро определяет, как быстро уменьшается влияние объекта при увеличении расстояния. Но на практике часто ширина окна влияет на качество сильнее, чем конкретный вид ядра.

6.7. Подбор параметров

Для выбора параметров модели используется leave-one-out оценка. При LOO для каждого объекта z_i модель строит прогноз без использования самого объекта z_i . Затем вычисляется ошибка:

$$\text{LOO RMSE} = \sqrt{\frac{1}{\ell} \sum_{i=1}^{\ell} (y_i - \hat{y}_i^{(-i)})^2}.$$

Подбираются следующие параметры:

- ширина окна h для фиксированного окна;
- число соседей k для переменного окна;
- вид ядра $K(r)$.

Оптимальными считаются параметры, при которых ошибка LOO минимальна. Важно, что подбор всегда проводится по обучающей выборке (через LOO), а не по тестовой; иначе оценка качества становится оптимистично смещённой.

7. Экспериментальное исследование метрических методов

7.1. Одномерная иллюстрация ядерного сглаживания

Для наглядного анализа ядерной регрессии была рассмотрена одномерная синтетическая задача:

$$y = \sin x + \varepsilon.$$

Такая задача позволяет визуально показать, как параметр h влияет на гладкость прогноза.




Рис. 9. Ядерная регрессия при разных значениях ширины окна




Рис. 10. Зависимость ошибки от ширины окна в одномерной задаче

7.2. Влияние ширины окна

Для ядерной регрессии с фиксированным окном исследовалась зависимость качества от параметра h . Малые значения h приводят к высокой чувствительности к шуму, а слишком большие значения — к чрезмерному сглаживанию.




Рис. 11. Зависимость ошибки ядерной регрессии от ширины окна

7.3. Влияние числа соседей

Для модели с переменным окном исследовалась зависимость качества от числа соседей k . Малое значение k делает модель слишком локальной, а большое значение k усиливает сглаживание.




Рис. 12. Зависимость ошибки от числа соседей для переменного окна

7.4. Сравнение ядер

Для оценки влияния формы ядра были сравнены различные ядерные функции. Для каждого ядра подбирались оптимальные параметры, после чего сравнивались значения ошибки на тестовой выборке.




Рис. 13. Сравнение ядерных функций по качеству прогноза

7.5. Сравнение фиксированного и переменного окна

Отдельно сравнивались лучшие модели с фиксированным и переменным окном. Переменное окно может выигрывать в случае неравномерной плотности данных, так как оно адаптируется к расположению объектов.




Рис. 14. Сравнение фиксированного и переменного окна

7.6. Анализ прогнозов и ошибок ядерной модели

Для лучшей ядерной модели были построены графики истинных и предсказанных значений, а также распределение остатков.




Рис. 15. Истинные и предсказанные значения для ядерной регрессии




Рис. 16. Распределение ошибок ядерной регрессии

7.7. Качество на реальных датасетах

Помимо синтетики, метрические методы были оценены на двух стандартных регрессионных датасетах из библиотеки `scikit-learn`. В таблице 2 приведены метрики на тестовой части (25 % от всей выборки).

Таблица 2. Метрические методы на реальных датасетах

Датасет	Модель	MAE	RMSE	R^2
Diabetes	NW fixed	47,6	57,9	0,460
Diabetes	NW variable	46,4	58,2	0,454
Diabetes	LOWESS	48,7	59,6	0,427
California	NW fixed	0,488	0,679	0,644
California	NW variable	0,491	0,674	0,649
California	LOWESS	0,508	0,720	0,600

На обоих реальных датасетах переменное окно даёт небольшой, но устойчивый выигрыш над фиксированным. LOWESS на чистых данных проигрывает обычной NW: за робастность приходится платить небольшим ухудшением метрик в отсутствие выбросов. Полные числа сохранены в `report_outputs/tables/final_model_comparison.csv`.

8. Робастная регрессия LOWESS

8.1. Идея метода

LOWESS является робастной модификацией локального сглаживания. Основная идея состоит в том, что объектам с большими ошибками постепенно уменьшаются веса.

На каждой итерации вычисляются LOO-прогнозы:

$$a_i = \frac{\sum_{j=1, j \neq i}^{\ell} y_j \gamma_j K\left(\frac{\rho(z_i, z_j)}{h(z_i)}\right)}{\sum_{j=1, j \neq i}^{\ell} \gamma_j K\left(\frac{\rho(z_i, z_j)}{h(z_i)}\right)}.$$

Затем вычисляются ошибки:

$$\varepsilon_i = |a_i - y_i|.$$

После этого объектные веса обновляются:

$$\gamma_i = \tilde{K}\left(\frac{|a_i - y_i|}{6 \operatorname{med}\{\varepsilon_i\}}\right),$$

где $\tilde{K}$ — биквадратное (квартическое) ядро. Если объект имеет большую

ошибку относительно медианы остатков, то его вес γ_i уменьшается. Поэтому выбросы начинают меньше влиять на прогноз.

Пояснение. Обычная ядерная регрессия может сильно страдать от выбросов, потому что выброс всё равно участвует в усреднении. LOWESS пытается обнаружить такие объекты по большим остаткам и уменьшить их влияние.

8.2. Исследование устойчивости к выбросам

Для проверки устойчивости моделей в данные добавлялись искусственные выбросы. После этого сравнивались обычная ядерная регрессия и LOWESS.




Рис. 17. Влияние выбросов на качество регрессии

8.3. Финальные веса LOWESS

После стабилизации алгоритма LOWESS можно проанализировать финальные веса объектов. Малые значения γ_i соответствуют объектам, которые алгоритм посчитал потенциальными выбросами.




Рис. 18. Финальные веса объектов в LOWESS

8.4. Одномерная иллюстрация LOWESS

Для наглядности также была рассмотрена одномерная задача с выбросами. На ней можно увидеть, как обычное сглаживание и LOWESS ведут себя при наличии аномальных наблюдений.




Рис. 19. Сравнение обычного сглаживания и LOWESS при выбросах

9. Сравнение линейного и метрического подходов

В работе были рассмотрены два класса методов.

Первый класс — линейные модели по функциональным признакам. Их преимущество состоит в интерпретируемости: модель можно записать через весовую функцию $w(t)$, которая показывает вклад разных участков исходной функции в прогноз. На сгенерированных данных, где истинная зависимость линейна по интегральным функционалам, этот подход даёт практически идеальное качество ($R^2 \approx 0,99$).

Второй класс — метрические методы регрессии. Они являются более гибкими, так как не предполагают глобальной линейной зависимости между признаками и ответом. Однако они сильнее зависят от выбора метрики, масштаба признаков, ширины окна и ядра. На реальных датасетах <<Diabetes>> и <<California Housing>> метрические методы достигают $R^2 \approx 0,46$ и $\approx 0,65$ соответственно, что сопоставимо с типичными значениями для этих задач.

Ridge-регрессия повышает устойчивость линейной модели за счёт штрафа на большие коэффициенты. LOWESS, в свою очередь, повышает устойчивость метрического подхода при наличии выбросов.

Пояснение. Если нужна интерпретируемая модель, удобнее использовать линейный подход через $w(t)$. Если зависимость сложная и нелинейная, могут быть полезны метрические методы. Если в данных есть выбросы, LOWESS может оказаться устойчивее обычного ядерного сглаживания.

Таблица 3. Качественное сравнение рассмотренных моделей

Метод	Преимущества	Ограничения
Линейная регрессия по функциональным признакам	Хорошо интерпретируется через весовую функцию $w(t)$	Требует, чтобы зависимость была близка к линейной
Ridge-регрессия	Более устойчива при большом числе признаков и похожих функционалах	Требует подбора параметра регуляризации λ
Надарая--Ватсона с фиксированным окном	Простая непараметрическая модель, учитывающая близость объектов	Сильно зависит от выбора ширины окна h
Надарая--Ватсона с переменным окном	Адаптируется к плотности данных	Требует подбора числа соседей k
LOWESS	Устойчивее к выбросам за счёт перевзвешивания объектов	Сложнее вычислительно и требует итерационного процесса

9.1. Ответы на исследовательские вопросы кейса 6

В задании кейса 6 явно поставлены три вопроса. Ниже приведены ответы по итогам экспериментов.

Вопрос 1. Что влияет сильнее — выбор ядра или выбор ширины окна?

В проведённых экспериментах размах LOO RMSE при изменении ширины окна составил порядка 0,018, а при смене ядра при фиксированном h — порядка 0,003. Таким образом, выбор ширины окна влияет на качество приблизительно в 5--6 раз сильнее. Это согласуется с теорией Парзена-Розенблатта: ширина окна задаёт скорость сходимости $n^{-4/5}$, а ядро влияет лишь на постоянную перед этой скоростью.

Вопрос 2. Когда переменное окно выигрывает у фиксированного?

Переменное окно оказывается лучше, когда плотность объектов $p(z)$ неоднородна. На равномерной одномерной синтетике выигрыш составляет порядка 1--2 %. На <<California Housing>>, где плотность признакового облака существенно неоднородна, выигрыш по R^2 более заметен (0,649 против

0,644), что подтверждает теоретическую интуицию: адаптивная ширина окна позволяет лучше использовать информацию в плотных областях и не разваливаться в разреженных.

Вопрос 3. При каком уровне загрязнения данных LOWESS начинает выигрывать у обычного сглаживания?

Уже при доле выбросов около 3 % LOWESS показывает существенно лучшее качество (test RMSE 0,176 против 0,221 у обычной NW). При более высоких уровнях загрязнения (15--20 %) обе модели страдают от попадания выбросов в тестовую выборку, но LOWESS сохраняет корректную форму прогноза за счёт малых γ_i у аномальных объектов. На полностью чистых данных LOWESS теряет около 2--3 % качества по сравнению с обычной NW — это плата за робастность.

9.2. Смысловая интерпретация результатов

С точки зрения функционального анализа линейная модель использует конечное число линейных функционалов для приближённого описания зависимости ответа от функции. Это означает, что вместо всей функции $x(t)$ модель использует её проекции на выбранные направления $\varphi_k(t)$.

Метрический подход использует уже не сами функции, а конечномерные представления, полученные через функционалы. Поэтому качество метрических методов зависит от того, насколько хорошо выбранные функционалы сохраняют существенную информацию о функциях.

Наиболее важным этапом оказывается построение признакового пространства. Если функционалы выбраны удачно, то и линейная модель, и метрические методы получают достаточно информации о форме исходной функции. Если же функционалы плохо отражают структуру данных, то дальнейшие методы работают с неполным представлением объекта.

Таким образом, общий результат можно сформулировать следующим образом: построение функциональных признаков является ключевым этапом, от которого зависит качество как линейных, так и метрических моделей.

Заключение

В работе была рассмотрена задача регрессии по функциональным данным. Исходные объекты задавались функциями на интервале $[0, 1]$, после чего преобразовывались в конечномерные векторы признаков с помощью линейных функционалов.

Были рассмотрены разные системы функционалов: индикаторы подотрезков, тригонометрический базис и полиномиальный базис. На полученных признаках была построена линейная регрессионная модель, выведены нормальные уравнения метода наименьших квадратов, а также реализована ridge-регрессия. Дополнительно была восстановлена весовая функция $w(t)$, позволяющая интерпретировать вклад разных участков исходной функции в прогноз.

Затем те же функциональные признаки были использованы для метрических методов регрессии. Были реализованы ядерная регрессия Надарая--Ватсона с фиксированной и переменной шириной окна, подбор параметров по LOO, сравнение четырёх ядер (гауссовское, треугольное, Епанечникова, биквадратное), а также робастная схема LOWESS. Дополнительно метрические методы оценены на стандартных датасетах <<Diabetes>> и <<California Housing>>.

По результатам экспериментов было показано, что линейная модель хорошо работает в случае, когда зависимость ответа от функции действительно близка к линейной комбинации функционалов. Её преимуществом является интерпретируемость, так как модель можно представить через весовую функцию $w(t)$. Метрические методы являются более гибкими и не требуют явного задания линейной формы зависимости. Однако их качество сильнее зависит от выбора метрики, ширины окна, ядра и масштаба признаков. При наличии выбросов робастная схема LOWESS позволяет уменьшить влияние аномальных объектов и повысить устойчивость прогноза.

Таким образом, кейс 4 и кейс 6 образуют единую исследовательскую схему: сначала функциональные данные переводятся в конечномерное признаковое пространство, затем в этом пространстве сравниваются параметрические и непараметрические методы регрессии.

Список использованных источников

1. Колмогоров А. Н., Фомин С. В. Элементы теории функций и функционального анализа. — М.: Наука, 1989.
2. Канторович Л. В., Акилов Г. П. Функциональный анализ. — М.: Наука, 1984.
3. Kreyszig E. Introductory Functional Analysis with Applications. — Wiley, 1989.
4. Ramsay J. O., Silverman B. W. Functional Data Analysis. — Springer, 2005.
5. Hastie T., Tibshirani R., Friedman J. The Elements of Statistical Learning. — Springer, 2009.
6. Bishop C. M. Pattern Recognition and Machine Learning. — Springer, 2006.
7. Nadaraya E. A. On estimating regression. Theory of Probability and Its Applications, 1964.
8. Watson G. S. Smooth regression analysis. Sankhya: The Indian Journal of Statistics, 1964.
9. Cleveland W. S. Robust locally weighted regression and smoothing scatterplots. Journal of the American Statistical Association, 1979.

А. Дополнительные материалы эксперимента

В ходе работы были автоматически сформированы таблицы с результатами экспериментов. Они сохранены в формате CSV в папке:

```
report_outputs/tables/.
```

К основным таблицам относятся:

- `dataset_description.csv` — описание используемых датасетов;
- `linearity_check.csv` — численная проверка линейности функционалов;
- `linear_basis_comparison.csv` — сравнение систем функционалов;
- `best_linear_models.csv` — лучшие линейные модели и `ridge`;
- `kernel_fixed_window_results.csv` — результаты NW с фиксированным окном;
- `kernel_variable_window_results.csv` — результаты NW с переменным окном;
- `best_kernel_models.csv` — лучшие метрические модели;
- `lowess_outlier_comparison.csv` — сравнение LOWESS и обычного сглаживания при выбросах;
- `lowess_final_weights.csv` — финальные веса объектов в LOWESS;
- `final_model_comparison.csv` — итоговое сравнение моделей.

В. Исходный код

Исходный код был реализован на языке Python (3.11) с использованием библиотек NumPy, scikit-learn (только для загрузки реальных датасетов и

стандартизации) и Matplotlib. В ходе работы были реализованы следующие модули:

- генерация синтетических функциональных данных;
- построение систем линейных функционалов (индикаторы, полиномы, тригонометрический базис);
- численное вычисление интегральных признаков методом трапеций;
- линейная регрессия и ridge-регрессия через нормальные уравнения;
- ядерная регрессия Надарая--Ватсона (fixed и variable window);
- четыре ядра: гауссовское, треугольное, Епанечникова, биквадратное;
- робастная схема LOWESS с биквадратным перевзвешиванием;
- векторизованный LOO-подбор гиперпараметров;
- построение всех графиков и CSV-таблиц для отчёта.

Воспроизведение всех графиков и таблиц достигается единственной командой:

```
PYTHONPATH=src python3 build_report_assets.py.
```

После запуска все артефакты автоматически сохраняются в папку `report_outputs/`, после чего отчёт можно скомпилировать командой

```
pdflatex report.tex.
```