

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**

**Федеральное государственное автономное образовательное учреждение
высшего образования**

Национальный исследовательский университет ИТМО

Факультет технологий искусственного интеллекта

Лабораторная работа

**по дисциплине
Функциональный анализ**

**Регрессия по функциональным данным:
линейные функционалы и метрические методы**

Кейсы №4 и №6

**Выполнил:
студент группы J3210
Тищенко Павел Валерьевич**

Исходный код: https://github.com/paulhowever/funkan_tischenko_j3210

Санкт-Петербург, 2026

1. Введение

В прикладных задачах объект наблюдения часто задаётся не вектором, а функцией $x(t)$, $t \in [0, 1]$ (временной ряд, сигнал датчика, профиль и т. п.). По функции требуется предсказать число $y \in \mathbb{R}$. Прямо учить регрессионную модель на функции нельзя: $L_2[0, 1]$ — бесконечномерное гильбертово пространство, а на дискретной сетке $N = 320$ точек — это всё ещё в среднем больше, чем число обучающих объектов. Поэтому функцию сначала надо «сжать» в конечномерный вектор признаков, не теряя существенной структуры.

Работа объединяет два подхода в одну схему:

$$x(t) \xrightarrow{\text{кейс 4}} z = (\langle x, \varphi_1 \rangle, \dots, \langle x, \varphi_m \rangle) \xrightarrow{\text{кейс 6}} \hat{y}.$$

Кейс 4 — параметрический подход: функция превращается в конечномерный вектор линейных функционалов, на котором обучается линейная (или ridge) регрессия; восстанавливается весовая функция $w(t)$, дающая глобально интерпретируемое предсказание.

Кейс 6 — непараметрические метрические методы: ядерная регрессия Надарая--Ватсона с фиксированным и переменным окном, а также робастная схема LOWESS. Эти методы применены и к признакам кейса 4, и к двум табличным датасетам — *Diabetes* и *California Housing*, чтобы оценить общность подхода на стандартных регрессионных задачах.

2. Данные

Синтетические функциональные данные:

$$x_i(t) = a_i \sin(2\pi t) + b_i \cos(2\pi t) + c_i t + \varepsilon_i(t), \quad y_i = 2 \int_0^1 x_i(t) \sin(2\pi t) dt - \int_0^1 x_i(t) t dt + \eta_i.$$

Истинная зависимость линейна по интегральным функционалам, шум функции ε_i и шум ответа η_i — нормальные. Такая конструкция выбрана специально: она позволяет проверить, насколько хорошо разные системы функционалов восстанавливают истинную весовую функцию $w(t) = 2 \sin(2\pi t) - t$.

Реальные датасеты: *Diabetes* (sklearn, $n = 442$, 10 признаков, целевая — индекс прогрессирования заболевания через год после базовых измерений) и *California Housing* (под-выборка $n = 3000$ из 20640, 8 признаков, медианная цена дома в $\$10^5$). Признаки стандартизуются на обучающей части (z-score). Это критично для метрических методов: иначе компонента с большим масштабом доминирует в евклидовом расстоянии, и модель фактически смотрит только на одну переменную.




Рис. 1. Примеры сгенерированных функциональных данных $x_i(t)$.

3. Кейс 4. Линейные функционалы и регрессия

3.1. Функционалы интегрального вида в $L_2[0, 1]$

Линейным функционалом называется отображение $L: L_2[0, 1] \rightarrow \mathbb{R}$, удовлетворяющее $L(\alpha x + \beta y) = \alpha L(x) + \beta L(y)$. Согласно теореме Рисса о представлении, любой непрерывный линейный функционал в гильбертовом пространстве $L_2[0, 1]$ имеет вид скалярного произведения с некоторым фиксированным элементом этого же пространства:

$$L_\varphi(x) = \langle x, \varphi \rangle = \int_0^1 x(t)\varphi(t) dt.$$

Функция $\varphi(t)$ играет роль шаблона: значение $L_\varphi(x)$ показывает, насколько $x(t)$ согласована с $\varphi(t)$. Линейность сразу следует из линейности интеграла:

$$L_\varphi(\alpha x + \beta y) = \int (\alpha x + \beta y)\varphi dt = \alpha \int x\varphi dt + \beta \int y\varphi dt = \alpha L_\varphi(x) + \beta L_\varphi(y).$$

Численная проверка для конкретной пары функционалов на одной из синтетических функций даёт $|L_\varphi(\alpha x + \beta y) - \alpha L_\varphi(x) - \beta L_\varphi(y)| \sim 10^{-9}$, что подтверждает корректность реализации (детали --- в `tables/linearity_check.csv`).

Каждой функции $x_i(t)$ ставится в соответствие конечномерный вектор:

$$z_i = (z_{i1}, \dots, z_{im}), \quad z_{ik} = \langle x_i, \varphi_k \rangle.$$

Сравниваются три системы функционалов:

- **индикаторы подотрезков** $\varphi_k = \mathbf{1}_{[\tau_{k-1}, \tau_k]}$ --- локальные средние значения функции на конкретном участке;
- **полиномы** $1, t, t^2, \dots, t^{m-1}$ --- гладкие тренды (моменты функции);
- **тригонометрический базис** $1, \sin(2\pi t), \cos(2\pi t), \sin(4\pi t), \dots$ --- амплитуды периодических компонент (короткий ряд Фурье).

3.2. Численное вычисление интегралов

Поскольку функции хранятся не аналитически, а на равномерной сетке $\{t_j\}_{j=0}^{N-1}$ с шагом Δt , скалярные произведения вычисляются по формуле трапеций:

$$\int_0^1 x(t)\varphi_k(t) dt \approx \sum_{j=0}^{N-2} \frac{x(t_j)\varphi_k(t_j) + x(t_{j+1})\varphi_k(t_{j+1})}{2} \Delta t.$$

Ошибка квадратуры имеет порядок $O(\Delta t^2)$ для гладких подынтегральных выражений; при $N = 320$ это $\sim 10^{-5}$, что заведомо меньше дисперсии шума η_i и поэтому не вносит систематического смещения в признаки.

3.3. Линейная регрессия и нормальные уравнения

После сборки матрицы признаков $Z \in \mathbb{R}^{n \times m}$ и расширения её столбцом единиц до $X = [1 | Z]$ модель имеет вид $\hat{y} = X\beta$. Метод наименьших квадратов минимизирует

$$Q(\beta) = \|y - X\beta\|^2 = (y - X\beta)^T (y - X\beta).$$

Градиент по β равен $\nabla Q = -2X^T(y - X\beta)$. Приравнивая нулю, получаем нормальные уравнения

$$X^T X \hat{\beta} = X^T y.$$

Гессиан $\nabla^2 Q = 2X^T X$ положительно полуопределён (а при полном столбцовом ранге X --- положительно определён), поэтому $\hat{\beta} = (X^T X)^{-1} X^T y$ --- глобальный минимум.

3.4. Ridge-регуляризация

При большом m или сильной зависимости функционалов матрица $X^T X$ становится плохо обусловленной, и оценки $\hat{\beta}$ начинают сильно колебаться от выборки к выборке. Ridge добавляет к функционалу штраф $\lambda \|\beta\|^2$ ($\lambda \geq 0$):

$$Q_\lambda(\beta) = \|y - X\beta\|^2 + \lambda \|\beta\|^2.$$

Соответствующие нормальные уравнения $(X^T X + \lambda I)\hat{\beta}_\lambda = X^T y$ дают замкнутое решение

$$\hat{\beta}_\lambda = (X^T X + \lambda I)^{-1} X^T y.$$

Матрица $X^T X + \lambda I$ всегда положительно определена при $\lambda > 0$, поэтому решение существует и единственно даже при сингулярном $X^T X$. Геометрически ridge сдвигает все собственные числа $X^T X$ на λ , что подавляет направления с малой собственной информативностью.

В терминах bias--variance: МНК-оценка несмещённая, но при плохой обусловленности её дисперсия растёт пропорционально $1/\lambda_{\min}(X^T X)$. Ridge вносит небольшое смещение $\sim \lambda$, но уменьшает дисперсию на порядок большую величину; при правильно подобранном λ суммарная MSE предсказания меньше, чем у обычного МНК. Это частный случай теоремы Джеймса-Стейна: в размерности ≥ 3 можно построить оценку, доминирующую несмещённую МНК-оценку по MSE.

3.5. Восстановление весовой функции

Линейная модель имеет вид

$$\hat{y}(x) = \beta_0 + \sum_{k=1}^m \beta_k \langle x, \varphi_k \rangle.$$

Введём $w(t) = \sum_{k=1}^m \beta_k \varphi_k(t)$. По линейности скалярного произведения:

$$\langle x, w \rangle = \left\langle x, \sum_k \beta_k \varphi_k \right\rangle = \sum_k \beta_k \langle x, \varphi_k \rangle,$$

поэтому $\hat{y}(x) = \beta_0 + \langle x, w \rangle$. Таким образом, бесконечномерная задача регрессии сведена к скалярному произведению с одной фиксированной функцией $w(t)$ --- это даёт прямую интерпретацию: участки t , где $|w(t)|$ велико, сильнее всего влияют на прогноз.




Рис. 2. Слева: восстановленные $w(t)$ для трёх базисов. Справа: лучший test RMSE по каждому базису.

3.6. Эксперименты

Метрики качества:

$$\text{MAE} = \frac{1}{n} \sum_i |y_i - \hat{y}_i|, \quad \text{MSE} = \frac{1}{n} \sum_i (y_i - \hat{y}_i)^2, \quad \text{RMSE} = \sqrt{\text{MSE}}, \quad R^2 = 1 - \frac{\text{SS}_{\text{res}}}{\text{SS}_{\text{tot}}}.$$

MAE устойчива к выбросам, RMSE сильнее штрафует большие ошибки (соответствует гауссовскому шуму), R^2 показывает долю объяснённой дисперсии и удобен для сравнения моделей в разных шкалах. Train/test разделяются как 75/25 случайной перестановкой объектов.




Рис. 3. Слева: зависимость test RMSE от числа функционалов m . Справа: зависимость test RMSE от λ (ridge).

Таблица 1. Лучшая линейная модель на синтетических данных.

Конфигурация	test RMSE	test MAE	test R^2
Тригонометрический, $m = 3$, $\lambda = 0$	~ 0.11	~ 0.07	~ 0.99
Лучший индикаторный, $m \approx 11$	~ 0.40	~ 0.30	~ 0.90
Лучший полиномиальный, $m \approx 5$	~ 0.55	~ 0.40	~ 0.80

Тригонометрический базис ожидаемо побеждает: целевая переменная задана через $\sin(2\pi t)$ и t , и функционалы напрямую согласованы с этой структурой (всего $m = 3$ функцио-

налов хватает, чтобы восстановить $w(t)$ почти идеально). Дальнейшее увеличение m не уменьшает test RMSE, а train продолжает падать --- это и есть переусложнение модели. Оптимальное λ близко к нулю: при малом m модель уже хорошо обусловлена и регуляризация не нужна.

Полиномиальный базис страдает оттого, что для воспроизведения $\sin(2\pi t)$ нужны много полиномов; индикаторный --- оттого, что кусочно-постоянная аппроксимация $\sin(2\pi t)$ принципиально шумит на стыках отрезков.

3.7. Связь с кейсом 6

Полученные векторы $z_i \in \mathbb{R}^m$ можно использовать не только в линейной модели, но и как входное представление для метрических методов следующего раздела. Удачно подобранный набор функционалов уменьшает размерность с бесконечной (или $N = 320$ на сетке) до $m \sim 3-15$, что критично для NW: скорость сходимости ядерной оценки в размерности d имеет вид $n^{-2/(4+d)}$, то есть катастрофически замедляется с ростом d (curse of dimensionality). Поэтому хорошие функциональные признаки --- ключевой шаг для последующего метрического анализа.




Рис. 4. Лучшая линейная модель: истинные vs предсказанные y (точки лежат вдоль диагонали) и распределение остатков (симметрично около нуля).

Гистограмма остатков на рисунке 4 симметрична около нуля и не имеет тяжёлых хвостов --- это означает, что модель не имеет систематических смещений и шум, не объяснённый моделью, действительно близок к гауссовскому. Это согласуется с генерацией данных: целевая переменная отличается от детерминированной части ровно на $\eta_i \sim \mathcal{N}(0, \sigma^2)$, и при идеальном восстановлении $w(t)$ остатки должны воспроизводить именно η_i .

В качестве sanity-check сравнения с train: gap между train RMSE и test RMSE при оптимальной конфигурации составляет ~ 0.01 , что говорит об отсутствии переобучения. При увеличении m за пределы оптимума gap начинает расти --- классический симптом переусложнения, видимый на рисунке 3 слева.

4. Кейс 6. Метрические методы

4.1. Гипотеза непрерывности и метрика

Метрические методы основаны на *гипотезе непрерывности*: близким объектам соответствуют близкие ответы. Формально --- предполагается, что условное математическое ожидание $f(x) = \mathbb{E}[y | x]$ непрерывно по x . В качестве метрики используется евклидово расстояние:

$$\rho(x, x_i) = \sqrt{\sum_{k=1}^m (x_k - x_{ik})^2}.$$

Для функциональных признаков из кейса 4 это просто евклидова метрика в $\mathbb{R}^m$. Для табличных признаков обязательна стандартизация --- иначе масштаб одной из координат подавит вклад остальных.

4.2. Оценка Надарая--Ватсона

Прогноз --- локально взвешенное среднее ответов обучающих объектов:

$$a(x; X^\ell, h) = \frac{\sum_{i=1}^{\ell} y_i K(\rho(x, x_i)/h)}{\sum_{i=1}^{\ell} K(\rho(x, x_i)/h)},$$

где $K(r)$ --- ядро (положительная неубывающая по $|r|$ функция, обычно $\int K = 1$), $h > 0$ --- ширина окна.

Эту оценку можно получить как решение задачи локально взвешенного МНК с константной локальной моделью $f(x_i) \approx \theta$:

$$Q(\theta; x) = \sum_{i=1}^{\ell} K(\rho(x, x_i)/h) (\theta - y_i)^2 \rightarrow \min_{\theta}.$$

Введя $w_i = K(\rho(x, x_i)/h)$, имеем $Q(\theta) = \sum w_i (\theta - y_i)^2$. Производная $\frac{dQ}{d\theta} = 2 \sum w_i (\theta - y_i) = 0$ даёт

$$\hat{\theta} = \frac{\sum w_i y_i}{\sum w_i},$$

вторая производная $2 \sum w_i > 0$ --- это глобальный минимум. Это в точности оценка Надарая--Ватсона.

4.3. Фиксированное и переменное окно

В фиксированном варианте $h = \text{const}$. Малое h приводит к высокой чувствительности к шуму (большая дисперсия), большое h --- к чрезмерному сглаживанию (большое смещение). Оптимум --- классический bias--variance tradeoff. Если расписать асимптотическое разложение MSE прогноза в точке x для гладкой регрессионной функции f , получится

$$\text{MSE}(x) \approx \underbrace{\left[\frac{h^2}{2} \mu_2(K) f''(x) \right]^2}_{\text{смещение}^2, \uparrow h} + \underbrace{\frac{\sigma^2 R(K)}{n h p(x)}}_{\text{дисперсия}, \downarrow h},$$

где $\mu_2(K) = \int r^2 K(r) dr$, $R(K) = \int K^2(r) dr$, $p(x)$ --- плотность распределения объектов. Минимизация по h даёт оптимальное $h^* \sim n^{-1/5}$, и при таком выборе RMSE убывает как $n^{-2/5}$. Видно, что ядро влияет только через постоянные $\mu_2(K)$ и $R(K)$, а h --- на сам порядок сходимости. Это и есть теоретическое объяснение, почему выбор h важнее выбора ядра.

В переменном варианте окно адаптируется к локальной плотности данных:

$$h(x) = \rho(x, x_{(k+1)}),$$

где $x_{(k+1)}$ --- $(k+1)$ -й по близости к x объект обучения. В плотных областях окно автоматически сужается, в разреженных --- расширяется. Это особенно полезно, если $p(x)$ существенно неоднородна.

4.4. Ядра

В работе сравниваются четыре ядра:

$$K_{\text{gauss}}(r) = \frac{1}{\sqrt{2\pi}} e^{-r^2/2}, \quad K_{\Delta}(r) = (1 - |r|) \mathbf{1}_{|r| \leq 1},$$

$$K_{\text{Epan}}(r) = \frac{3}{4} (1 - r^2) \mathbf{1}_{|r| \leq 1}, \quad K_{\text{quart}}(r) = \frac{15}{16} (1 - r^2)^2 \mathbf{1}_{|r| \leq 1}.$$

Гауссовское ядро имеет неограниченный носитель, остальные три --- компактный $|r| \leq 1$. Ядро Епанечникова в смысле минимума асимптотической MSE --- оптимально, однако константа эффективности у других ядер очень близка к 1 (различие меньше 5%), поэтому на практике выбор ядра играет существенно меньшую роль, чем выбор h .

4.5. Геометрический смысл оценки

Числитель и знаменатель в формуле NW можно прочесть как ядерные оценки соответственно $p(x) \cdot \mathbb{E}[y | x]$ и $p(x)$:

$$\hat{p}(x) = \frac{1}{nh^d} \sum_i K(\rho(x, x_i)/h), \quad \widehat{p \cdot f}(x) = \frac{1}{nh^d} \sum_i y_i K(\rho(x, x_i)/h).$$

Тогда $a(x) = \widehat{p \cdot f}(x)/\hat{p}(x)$ --- эмпирическая версия отношения $\mathbb{E}[y; x]/p(x) = \mathbb{E}[y | x]$. С такой точки зрения NW --- просто plug-in оценка условного матожидания через ядерную оценку плотности (Парзена--Розенблатта).

В терминах локальной полиномиальной регрессии NW --- это локальный полином степени 0. При замене константы θ на линейную функцию $\theta_0 + \theta_1^T(x_i - x)$ получается LOWESS первого порядка (LOESS), а ещё более высокая степень --- локальная квадратичная регрессия. В рамках этой работы используется только степень 0, поскольку именно она задана в условии задания.

4.6. Подбор гиперпараметров через LOO

h , k и тип ядра подбираются по leave-one-out RMSE на обучающей части:

$$\text{LOO RMSE} = \sqrt{\frac{1}{\ell} \sum_{i=1}^{\ell} (y_i - \hat{y}_i^{(-i)})^2},$$

где $\hat{y}_i^{(-i)}$ --- прогноз модели, обученной на $\ell - 1$ объектах без i -го. Важно: подбор всегда производится по обучающей части; использовать тестовую выборку для подбора --- значит получить оптимистично смещённую оценку качества и смешать выбор модели с её оценкой. Для NW LOO считается без полной переобучки модели за $O(\ell^2)$ операций: достаточно один раз построить матрицу ядерных весов и обнулить диагональ.

4.7. Эксперименты на одномерной синтетике

Задача $y = \sin x + \varepsilon$ позволяет визуально оценить роль h .




Рис. 5. 1D синтетика $y = \sin x + \varepsilon$. Слева: NW при разных h . Справа: классическая U-образная зависимость $\text{RMSE}(h)$.




Рис. 6. LOO RMSE для четырёх ядер: слева от h , справа от k . Кривые ядер почти сливаются --- ядро влияет слабо.




Рис. 7. Слева: лучшая модель по каждому ядру --- все четыре дают практически одинаковое качество. Справа: фиксированное vs переменное окно.




Рис. 8. Лучшая ядерная модель: предсказание и распределение остатков.

4.8. Качество на реальных датасетах

Таблица 2. Метрические методы на реальных датасетах (стандартизованные признаки, train/test = 75/25).

Датасет	Модель	MAE	RMSE	R^2
Diabetes	NW fixed	47.6	57.9	0.460
Diabetes	NW variable	46.4	58.2	0.454
Diabetes	LOWESS	48.7	59.6	0.427
California	NW fixed	0.488	0.679	0.644
California	NW variable	0.491	0.674	0.649
California	LOWESS	0.508	0.720	0.600

На обоих реальных датасетах переменное окно даёт небольшой, но устойчивый выигрыш над фиксированным. На *California Housing* это выражено заметнее --- плотность облака признаков сильно неоднородна (кластеры пригородов и городские агломерации), и адаптивная ширина окна выгоднее. LOWESS на чистых данных проигрывает обычной NW: за робастность приходится платить небольшим ухудшением метрик в отсутствие выбросов.

Стоит отметить, что качество $R^2 \approx 0.46$ на *Diabetes* --- это типичный потолок для непараметрических методов на этом датасете без сильного feature engineering, при том что обычная линейная регрессия на нём же выдаёт $R^2 \approx 0.45$ --0.50. На *California Housing* достигнутый $R^2 \approx 0.65$ ощутимо лучше линейной regression baseline ($R^2 \approx 0.60$), но уступает gradient boosting и нейросетям ($R^2 \approx 0.83$). NW не страдает от мультиколлинеарности признаков, но всё ещё проседает в высокой размерности из-за curse of dimensionality.

5. Робастная схема LOWESS

5.1. Идея и формулы

Обычная NW считает все объекты равноправными, и единственный выброс может ощутимо сместить прогноз в своей окрестности. LOWESS --- итеративный М-оценитель: он вычисляет невязки, понижает веса объектам с большими невязками и пересчитывает прогноз. На каждой итерации:

$$a_i = \frac{\sum_{j \neq i} y_j \gamma_j K(\rho(x_i, x_j)/h(x_i))}{\sum_{j \neq i} \gamma_j K(\rho(x_i, x_j)/h(x_i))}, \quad \varepsilon_i = |a_i - y_i|,$$

$$\gamma_i = \tilde{K}\left(\frac{\varepsilon_i}{6 \operatorname{med}\{\varepsilon\}}\right), \quad \tilde{K}(u) = (1 - u^2)^2 \mathbf{1}_{|u| < 1}.$$

$\tilde{K}$ --- биквадратное (квартическое) ядро. Стартовые $\gamma_i = 1$; итерации продолжаются до тех пор, пока $\max_i |a_i^{(t)} - a_i^{(t-1)}|$ не упадёт ниже порога (10^{-5} в реализации).

5.2. Почему именно эта формула

Множитель $6 \operatorname{med}\{\varepsilon\}$ --- робастная оценка масштаба невязок. Для нормально распределённых остатков медиана модулей даёт несмещённую оценку σ при умножении на ≈ 1.483 . Поэтому $6 \operatorname{med}\{\varepsilon\} \approx 4\sigma$: объекты, чьи невязки выходят за 4σ , получают $\gamma_i = 0$ и полностью игнорируются. Это делает LOWESS нечувствительным к примерно 25% выбросов произвольной величины и при этом сохраняющим эффективность близкой к 95% для нормального шума.

Биквадратное ядро выбрано как компромисс между поведением Tukey и эффективностью: оно гладко спадает к нулю на границе $|u| = 1$, в отличие от резкого Hampel, и за счёт квадрата обеспечивает C^1 -непрерывность весовой функции по невязкам, что улучшает сходимость.

5.3. Связь с М-оценками

Хотя у LOWESS нет фиксированной функции потерь, его удобно интерпретировать как обобщение М-оценок Хьюбера и Тьюки на случай локальной непараметрической регрессии. Классическая М-оценка $\hat{\theta} = \arg \min_{\theta} \sum \rho(y_i - \theta)$ через дифференцирование сводится к итеративной перевзвешенной задаче МНК с весами $\gamma_i = \rho'(\varepsilon_i)/\varepsilon_i$. Для функции $\rho_{\text{Tukey}}(\varepsilon) = \frac{c^2}{6}(1 - (1 - (\varepsilon/c)^2)^3)$ при $|\varepsilon| < c$ и $c^2/6$ иначе ровно получается $\gamma_i = (1 - (\varepsilon_i/c)^2)^2$ при $|\varepsilon_i| < c$ --- то есть биквадратное ядро. LOWESS делает то же самое, только применяя процесс не глобально, а локально, в каждой точке оценки: для каждого i строит свою взвешенную ядерную оценку и обновляет γ_i по локальным невязкам. Параметр $c = 6 \text{ med}\{\varepsilon\}$ выбирается данным: это адаптивная оценка масштаба шума.

5.4. Иллюстрация на одномерной задаче с выбросами




Рис. 9. Слева: NW и LOWESS на 1D с выбросами --- обычная NW искажена выбросами, LOWESS их игнорирует. Справа: финальные γ_i --- для выбросов значения близки к 0.




Рис. 10. Test RMSE как функция доли выбросов в обучении. С ростом загрязнения NW резко теряет качество, LOWESS остаётся устойчивым.

5.5. Сходимость

Строгих гарантий сходимости итерационной схемы LOWESS в общем случае нет: задача не сводится к минимизации какого-либо явного функционала (веса γ_i зависят от текущих невязок, и градиентного спуска относительно фиксированной целевой функции тут не получается). На практике, однако, схема демонстрирует устойчивое затухание: за 5--10 итераций изменение

прогнозов падает ниже 10^{-5} . Эмпирически количество итераций до сходимости почти не зависит от n , что объясняет вычислительную приемлемость метода: $O(\ell^2)$ работы на итерацию, $O(\ell^2 T)$ суммарно с $T \sim 10$.

5.6. Замечание о реализации

Аккуратная реализация LOWESS требует одной осторожности: при $\text{med}\{\varepsilon\} \rightarrow 0$ (например, на тривиальной выборке, где модель попадает в y точно) деление в $\tilde{K}$ становится бессмысленным. В таком случае итерации останавливаются и возвращается уже посчитанный прогноз a , а не неинициализированный буфер. На это есть отдельный регрессионный тест в коде, который специально проверяет, что для константного y возвращается константа, а не нули.

6. Итоги

6.1. Сравнение подходов

Линейная модель по функциональным признакам *интерпретируема* через $w(t)$ и на сгенерированных данных, где истинная зависимость линейна по интегральным функционалам, даёт $R^2 \approx 0.99$. Метрические методы более *гибкие* и не требуют формы зависимости, но сильнее зависят от выбора метрики и параметров. На реальных задачах (*Diabetes, California*) они достигают $R^2 \approx 0.46$ и 0.65 соответственно --- сопоставимо с типичным качеством линейных моделей и kernel-ridge на этих датасетах. Ridge стабилизирует линейную модель за счёт штрафа на коэффициенты; LOWESS --- метрическую при наличии выбросов за счёт перевзвешивания объектов.

С точки зрения функционального анализа оба подхода работают над одним и тем же конечномерным представлением: линейная модель ищет одну функцию-шаблон $w(t)$, а метрические методы --- локальное среднее в евклидовой окрестности признакового вектора. Качество и того, и другого подхода в первую очередь определяется тем, насколько удачно выбраны функционалы φ_k .

Обе модели имеют свои слепые зоны. Линейная модель формирует один глобальный шаблон $w(t)$ и не способна моделировать задачи, в которых разным регионам пространства признаков соответствуют принципиально разные зависимости. Метрические методы, напротив, локальны и хорошо ловят такую структуру, но плохо экстраполируют за пределы данных --- в области, где обучающих точек мало, оценка вырождается в среднее. Поэтому на практике эти два подхода скорее дополняют друг друга, чем конкурируют: одна модель служит интерпретируемой baseline, другая --- более гибким детектором локальных эффектов.

6.2. Ответы на исследовательские вопросы кейса 6

(1) Что важнее --- ядро или ширина окна? Ширина окна. Размах LOO RMSE при изменении h составил ~ 0.018 , а при смене ядра при фиксированном h --- ~ 0.003 , то есть в 5--6 раз меньше. Это согласуется с теорией Парзена--Розенблатта: h задаёт скорость сходимости $n^{-4/5}$, ядро --- лишь константу при ней.

(2) Когда переменное окно выигрывает? При неоднородной плотности $p(x)$. На равномерной 1D-синтетике выигрыш минимален (~ 1 --2%), на *California Housing* (где плотность признакового облака сильно неоднородна) --- R^2 0.649 против 0.644.

(3) При какой доле выбросов LOWESS лучше? Уже от $\sim 3\%$ выбросов LOWESS заметно лучше (test RMSE 0.176 vs 0.221 у NW). На полностью чистых данных платится ~ 2 --3% качества за робастность; начиная с ~ 6 --10% загрязнения LOWESS строго лучше. При 20% выбросов NW деградирует почти втрое относительно своего качества на чистых данных, тогда как LOWESS остаётся почти на том же уровне.

6.3. Практический алгоритм выбора модели

По итогам экспериментов имеет смысл следующий workflow при работе с регрессионной задачей:

1. **Если данные --- функции:** начать с линейных функционалов и подбора их числа m по test/CV. Тригонометрический и B-spline базисы --- хорошие умолчания; индикаторы --- если ожидаются ступеньки.
2. **Если зависимость близка к линейной:** линейная модель + ridge --- интерпретируемая baseline. Восстановленная $w(t)$ позволяет ответить на вопрос какие участки сигнала важны.
3. **Если есть подозрение на нелинейность:** перейти к NW. Подбирать h по LOO, не по тесту. Эпанечников или гауссовское ядро --- разница пренебрежимо мала.
4. **Если плотность признаков сильно неоднородна:** попробовать переменное окно (kNN-bandwidth).
5. **Если есть подозрение на выбросы (тяжёлые хвосты остатков):** включить LOWESS. Особенно полезен при доле загрязнения $\geq 5\%$.
6. **Если размерность $d > 10$:** ядерные методы начинают существенно проседать. Тогда либо снижать размерность (PCA / autoencoder), либо переходить к параметрическим / древесным моделям.

Линейная модель и метрические методы хорошо дополняют друг друга. Линейная модель даёт глобальную интерпретацию через $w(t)$ и быстрая в инференсе ($O(m)$ на точку). Метрические методы более выразительны, но обучение по сути отсутствует, а инференс дорог: $O(\ell)$ на точку для NW, $O(\ell \cdot T)$ для LOWESS. Это означает, что выбор подхода --- это выбор не только между качеством и интерпретируемостью, но и между стоимостью обучения и стоимостью предсказания.